

DBG_V5

May 22, 2025

```
[1]: # Librerías necesarias
import os
import re # Import the regular expression module

import pandas as pd
import numpy as np
import math
from math import ceil

import matplotlib
#matplotlib.use('TKAgg')
import matplotlib.pyplot as plt
from matplotlib.ticker import ScalarFormatter
import seaborn as sns
from mpl_toolkits.mplot3d import Axes3D

import time
import warnings
warnings.filterwarnings("ignore")

# Para guardar y cargar modelos
import joblib

# Librerías de preprocesado y modelado de scikit-learn
from sklearn.model_selection import train_test_split, KFold, cross_val_predict,
    GridSearchCV, cross_val_score
from sklearn import model_selection
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline
from sklearn import set_config
from sklearn.metrics import mean_squared_error, r2_score
from sklearn.linear_model import LinearRegression
from sklearn.cross_decomposition import PLSRegression
from sklearn.gaussian_process import GaussianProcessRegressor
from sklearn.gaussian_process.kernels import RBF, WhiteKernel, ConstantKernel,
    as C
```

```

from sklearn.svm import SVR
from sklearn.multioutput import MultiOutputRegressor
from sklearn.ensemble import RandomForestRegressor
from sklearn.neural_network import MLPRegressor

import keras
from keras.layers import Dense
from keras.models import Sequential

import tensorflow as tf
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

from scikeras.wrappers import KerasRegressor
from sklearn.base import BaseEstimator, RegressorMixin

from skopt import BayesSearchCV
from skopt.space import Real, Integer, Categorical

import time
import warnings
warnings.filterwarnings("ignore")

# Para guardar y cargar modelos
import joblib

```

```

[2]: # Clase auxiliar que convierte un diccionario en un objeto con atributos.
class TagBunch:
    def __init__(self, d):
        self.__dict__.update(d)

# Monkey-patch: asignar __sklearn_tags__ al wrapper para evitar el error
# Definición del wrapper personalizado para KerasRegressor
class MyKerasRegressorWrapper(BaseEstimator, RegressorMixin):
    def __init__(self, model, hidden_layer_size=50, hidden_layer_size_2=3,
↳ epochs=100, **kwargs):
        """
        model: función que construye el modelo (por ejemplo, create_model)
        hidden_layer_size, hidden_layer_size_2, epochs: parámetros a pasar a la
↳ función
        kwargs: otros parámetros (como batch_size, verbose, etc.)
        """
        self.model = model
        self.hidden_layer_size = hidden_layer_size
        self.hidden_layer_size_2 = hidden_layer_size_2
        self.epochs = epochs

```

```

self.kwargs = kwargs
self.estimator_ = None # Se llenará al entrenar

def fit(self, X, y, **fit_params):
    # Se crea la instancia interna de KerasRegressor usando scikeras.
    self.estimator_ = KerasRegressor(
        model=self.model,
        hidden_layer_size=self.hidden_layer_size,
        hidden_layer_size_2=self.hidden_layer_size_2,
        epochs=self.epochs,
        **self.kwargs
    )
    self.estimator_.fit(X, y, **fit_params)
    return self

def predict(self, X):
    return self.estimator_.predict(X)

def score(self, X, y):
    return self.estimator_.score(X, y)

def get_params(self, deep=True):
    params = {
        "model": self.model,
        "hidden_layer_size": self.hidden_layer_size,
        "hidden_layer_size_2": self.hidden_layer_size_2,
        "epochs": self.epochs,
    }
    params.update(self.kwargs)
    return params

def set_params(self, **parameters):
    for key, value in parameters.items():
        setattr(self, key, value)
    return self

def __sklearn_tags__(self):
    # NUEVO: Devolver un objeto TagBunch en lugar de un dict.
    return TagBunch({
        "requires_fit": True,
        "X_types": ["2darray"],
        "preserves_dtype": [np.float64],
        "allow_nan": False,
        "requires_y": True,
    })

def __sklearn_is_fitted__(self):

```

```
return self.estimator_ is not None
```

```
[3]: # =====  
# Definición de un wrapper para desescalar la predicción del target  
# =====  
from sklearn.base import BaseEstimator, RegressorMixin  
from sklearn.metrics import r2_score  
  
class DescaledRegressor(BaseEstimator, RegressorMixin):  
    """  
    Wrapper para un modelo cuya salida se entrenó sobre y escalado y que,  
    al predecir, se desescala automáticamente usando el target_scaler.  
    """  
    def __init__(self, estimator, target_scaler):  
        self.estimator = estimator # Modelo previamente entrenado (pipeline)  
        self.target_scaler = target_scaler # Escalador entrenado sobre y_train  
  
    def predict(self, X):  
        # Se predice en la escala del target (y escalado)  
        y_pred_scaled = self.estimator.predict(X)  
        # Se aplica la transformación inversa para recuperar la escala original  
        return self.target_scaler.inverse_transform(y_pred_scaled)  
  
    def fit(self, X, y):  
        # Aunque el modelo ya esté entrenado, este método permite reentrenarlo  
        y_scaled = self.target_scaler.transform(y)  
        self.estimator.fit(X, y_scaled)  
        return self  
  
    def score(self, X, y):  
        # Calcula  $R^2$  usando las predicciones ya desescaladas  
        y_pred = self.predict(X)  
        return r2_score(y, y_pred)  
  
class SingleOutputDescaledRegressor(BaseEstimator, RegressorMixin):  
    """  
    Wrapper para obtener la predicción de un modelo multioutput  
    para una variable de salida particular y desescalarla usando el  
    target_scaler. Se utiliza el índice de la columna deseada.  
    """  
    def __init__(self, estimator, target_scaler, col_index):  
        self.estimator = estimator # Modelo multioutput previamente  
        ↪ entrenado  
        self.target_scaler = target_scaler # Escalador entrenado sobre  
        ↪ y_train  
        self.col_index = col_index # Índice de la variable de salida
```

```

def predict(self, X):
    # Se predice con el modelo multioutput; se obtiene la predicción en
    ↪escala (2D array)
    y_pred_scaled = self.estimator.predict(X)
    # Se extrae la predicción para la columna de interés
    single_pred_scaled = y_pred_scaled[:, self.col_index]
    # Se recuperan los parámetros del escalador para la columna
    scale_val = self.target_scaler.scale_[self.col_index]
    mean_val = self.target_scaler.mean_[self.col_index]
    # Desescalar manualmente: valor original = valor escalado * escala +
    ↪media
    y_pred_original = single_pred_scaled * scale_val + mean_val
    return y_pred_original

def fit(self, X, y):
    # (Opcional) Si se desea reentrenar el modelo, se transforma y y se
    ↪ajusta
    y_scaled = self.target_scaler.transform(y)
    self.estimator.fit(X, y_scaled)
    return self

def score(self, X, y):
    from sklearn.metrics import r2_score
    y_pred = self.predict(X)
    return r2_score(y, y_pred)

class UnifiedDescaledRegressor(BaseEstimator, RegressorMixin):
    """
    Modelo que encapsula un diccionario de modelos individuales (por variable
    ↪de salida).
    Cada modelo (del tipo SingleOutputDescaledRegressor) se utiliza para
    ↪predecir su variable
    de salida correspondiente y se realiza la transformación inversa para
    ↪retornar el valor original.
    """
    def __init__(self, models):
        """
        :param models: diccionario con llave = etiqueta de salida y valor =
        ↪SingleOutputDescaledRegressor.
        """
        self.models = models
        # Se conserva el orden de salida en función de las claves del
        ↪diccionario;
        # se asume que estas claves son exactamente las mismas que aparecen en
        ↪y_test.
        self.output_columns = list(models.keys())

```

```

def predict(self, X):
    preds = []
    # Se predice para cada variable en el orden de self.output_columns
    for col in self.output_columns:
        model = self.models[col]
        pred = model.predict(X) # cada predicción es un array de forma
↪(n_samples,)
        preds.append(pred)
    # Se combinan las predicciones columna a columna para formar un array
↪(n_samples, n_targets)
    return np.column_stack(preds)

def score(self, X, y):
    from sklearn.metrics import r2_score
    y_pred = self.predict(X)
    return r2_score(y, y_pred, multioutput='uniform_average')

```

```

[4]: # =====
# 1. CARGA DE DATOS Y PREPARACIÓN DEL DATAFRAME
# =====
# Definir las rutas base y de las carpetas
base_path = os.getcwd() # Se asume que el notebook se ejecuta desde la carpeta
↪'DBG'
db_path = os.path.join(base_path, "DB_DBG")
fig_path = os.path.join(base_path, "Figuras_DBG")
model_path = os.path.join(base_path, "Modelos_DBG")

# Ruta al archivo de la base de datos
data_file = os.path.join(db_path, "design_DB_preprocessed_5000_Uniforme.csv")
print(data_file)

# Ruta al archivo de las figuras
figure_path = os.path.join(fig_path, "5000_MOT_Uniforme")
print(figure_path)

# Ruta al archivo de los modelos
modelo_path = os.path.join(model_path, "5000_MOT_Uniforme")
print(modelo_path)

# Lectura del archivo CSV
try:
    df = pd.read_csv(data_file)
    print("Archivo cargado exitosamente.")
except FileNotFoundError:
    print("Error: Archivo no encontrado. Revisa la ruta del archivo.")
except pd.errors.ParserError:

```

```

    print("Error: Problema al analizar el archivo CSV. Revisa el formato del_
↪archivo.")
except Exception as e:
    print(f"Ocurrió un error inesperado: {e}")

# Función para limpiar nombres de archivo inválidos
def clean_filename(name):
    return re.sub(r'[\\"/*?:"<>|]', "_", name)

```

C:\Users\s00244\Documents\GitHub\MotorDesignDataDriven\Notebooks_TFM\4.DBG\DB_DB
G\design_DB_preprocessed_5000_Uniforme.csv
C:\Users\s00244\Documents\GitHub\MotorDesignDataDriven\Notebooks_TFM\4.DBG\Figuras
DBG\5000_MOT_Uniforme
C:\Users\s00244\Documents\GitHub\MotorDesignDataDriven\Notebooks_TFM\4.DBG\Model
os_DBG\5000_MOT_Uniforme
Archivo cargado exitosamente.

```

[5]: # =====
# 2. SEPARACIÓN DE VARIABLES
# =====
# Se separan las columnas según prefijos:
#   - Variables 'x' (inputs principales)
#   - Variables 'm' (otras características del motor)
#   - Variables 'p' (salidas: parámetros a predecir)
X_cols = [col for col in df.columns if col.startswith('x')]
M_cols = [col for col in df.columns if col.startswith('m')]
P_cols = [col for col in df.columns if col.startswith('p')]

# Se crea el DataFrame de características y del target. En este ejemplo se usa_
↪X (inputs)
# y P (salidas), pero se pueden incluir también las M si así se requiere.
X = df[X_cols].copy()
M = df[M_cols].copy()
P = df[P_cols].copy()
y = df[P_cols].copy() # Usamos las columnas p para las predicciones

# Convertir todas las columnas a tipo numérico en caso de haber algún dato no_
↪numérico
for col in X.columns:
    X[col] = pd.to_numeric(X[col], errors='coerce')
for col in M.columns:
    M[col] = pd.to_numeric(M[col], errors='coerce')
for col in P.columns:
    P[col] = pd.to_numeric(P[col], errors='coerce')
for col in y.columns:
    y[col] = pd.to_numeric(y[col], errors='coerce')

```

```

# Concatena las matrices X y M
X_M = pd.concat([X, M], axis=1)

print("\nPrimeras filas de X:")
display(X.head())
print("\nPrimeras filas de y (P):")
display(y.head())

print("Columnas de salida originales:", y.columns.tolist())

# Definir un umbral para la varianza
threshold = 1e-8 # Este umbral puede ajustarse según la precisión deseada

# Calcular la varianza de cada columna del DataFrame y
variances = y.var()
print("\nVariancia de cada columna de salida:")
print(variances)

# Seleccionar aquellas columnas cuya varianza es mayor que el umbral
cols_to_keep = variances[variances > threshold].index
y = y[cols_to_keep]

# Filtrar las filas del DataFrame y para eliminar aquellas que contienen NaN
Y = y.dropna() # Se eliminan todas las filas con al menos un valor NaN en y
# Actualizar X para que quede alineado con los índices de y
X = X.loc[Y.index]

features = list(X.columns)
outputs = [col for col in Y.columns]

print("\nColumnas de salida tras eliminar las constantes o casi constantes:")
print(Y.columns.tolist())

```

Primeras filas de X:

	x1::OSD	x2::Dint	x3::L	x4::tm	x5::hs2	x6::wt	x7::Nt	x8::Nh
0	48.60	27.8640	14.800000	2.780311	6.312467	4.392325	6	4
1	59.40	24.0560	29.200000	2.121244	10.249868	2.569301	12	3
2	54.72	32.0528	22.960001	2.456926	7.797124	2.123813	18	3
3	48.84	21.9616	25.120000	3.032072	6.972909	2.557345	14	3
4	59.76	27.1024	29.680002	3.249535	8.141503	4.802138	10	3

Primeras filas de y (P):

	p1::W	p2::Tnom	p3::nnom	p4::GFF	p5::BSP_T	p6::BSP_n	p7::BSP_Pm	\
0	0.322074	0.11	3960.0	40.082718	0.170606	17113.2340	305.74252	

1	0.674799	0.11	3960.0	24.675780	0.412852	4913.5480	212.43124
2	0.535554	0.11	3960.0	42.652370	0.538189	3806.5370	214.53262
3	0.487619	0.11	3960.0	57.017277	0.380920	5161.0967	205.87508
4	0.749844	0.11	3960.0	37.444870	0.429127	4961.4146	222.95651

	p8::BSP_Mu	p9::BSP_Irms	p10::MSP_n	p11::UWP_Mu
0	90.763855	10.070335	18223.3200	86.138150
1	87.076820	7.558135	5737.1406	88.799880
2	83.929474	7.553457	4325.1235	83.402340
3	87.040310	7.554095	6293.4336	91.343490
4	89.363690	7.554099	5615.5110	91.807846

Columnas de salida originales: ['p1::W', 'p2::Tnom', 'p3::nnom', 'p4::GFF', 'p5::BSP_T', 'p6::BSP_n', 'p7::BSP_Pm', 'p8::BSP_Mu', 'p9::BSP_Irms', 'p10::MSP_n', 'p11::UWP_Mu']

Variancia de cada columna de salida:

p1::W	2.409097e-02
p2::Tnom	1.733798e-33
p3::nnom	0.000000e+00
p4::GFF	1.216293e+02
p5::BSP_T	5.526305e-02
p6::BSP_n	2.691714e+07
p7::BSP_Pm	1.675008e+04
p8::BSP_Mu	7.538927e+00
p9::BSP_Irms	2.199128e+01
p10::MSP_n	3.204081e+07
p11::UWP_Mu	8.609559e+00

dtype: float64

Columnas de salida tras eliminar las constantes o casi constantes:

['p1::W', 'p4::GFF', 'p5::BSP_T', 'p6::BSP_n', 'p7::BSP_Pm', 'p8::BSP_Mu', 'p9::BSP_Irms', 'p10::MSP_n', 'p11::UWP_Mu']

```
[6]: # =====
# Paso 3: Definir el modelo ANN_K para que pueda leerse
# =====
import json

# Supongamos que el JSON está en la raíz del proyecto y se llama
↳ 'hiperparametros_MOP.json'
params_file = os.path.join(modelo_path, "hiperparametros_DBG.json")
try:
    with open(params_file, "r") as f:
        hiperparametros = json.load(f)
    print(f"Hiperparámetros cargados desde {params_file}")
except FileNotFoundError:
    print(f"No se encontró el archivo de hiperparámetros: {params_file}")
```

```

param_grids = {}

# Asegurarnos de tener diccionario con cada modelo
hiperparametros = {
    "PLS": hiperparametros.get("PLS", {}),
    "LR": hiperparametros.get("LR", {}),
    "GPR": hiperparametros.get("GPR", {}),
    "SVR": hiperparametros.get("SVR", {}),
    "RF": hiperparametros.get("RF", {}),
    "ANN": hiperparametros.get("ANN", {}),
    "ANN-K": hiperparametros.get("ANN-K", {}),
}

akk_par = hiperparametros['ANN-K']
bs = akk_par.get('model__batch_size')
h1 = akk_par.get('model__hidden_layer_size')
h2 = akk_par.get('model__hidden_layer_size_2')
ep = akk_par.get('model__epochs')

n_cols = X.shape[1]
n_out = y.shape[1] # El modelo debe producir n_out salidas

# Definir la función que crea el modelo Keras
# @tf.function(reduce_retracing=True)
def ANN_K_model(hidden_layer_size=h1, hidden_layer_size_2=h2):
    model = Sequential()
    model.add(Dense(hidden_layer_size, activation='relu',
        ↪input_shape=(n_cols,)))
    model.add(Dense(hidden_layer_size_2, activation='relu'))
    model.add(Dense(n_out))
    model.compile(loss='mean_squared_error', optimizer='adam')
    return model

# Envolver el modelo en KerasRegressor para utilizarlo con scikit-learn
my_keras_reg = MyKerasRegressorWrapper(
    model=ANN_K_model,
    hidden_layer_size=h1,
    hidden_layer_size_2=h2,
    epochs=ep,
    random_state=42,
    verbose=0
)

```

Hiperparámetros cargados desde C:\Users\s00244\Documents\GitHub\MotorDesignDataD
riven\Notebooks_TFM\4.DBG\Modelos_DBG\5000_MOT_Uniforme\hiperparametros_DBG.json

```
[7]: # =====
# Paso 4: Generar 10,000 nuevos motores a partir de los rangos de entrada
# =====
# Las restricciones (Boundaries B) se definen sobre las variables de X y de M.
# Definir la función check_boundaries escalable: se evalúan todas las
↳ condiciones definidas en una lista.
def check_boundaries(row):
    boundaries = [
        lambda r: r['x1::OSD'] > r['x2::Dint'], # Boundarie_1: x1 debe ser
↳ mayor que x2
        lambda r: 45.0 < r['x1::OSD'] < 60.0, # Boundarie_2: x1 debe
↳ estar entre 45 y 60.
        lambda r: ((r['x2::Dint']-2*0.5)-2*r['x4::tm']-r['x2::Dint']/3.5) >= 8,
↳ # Boundarie_3: Dsh debe ser mayor 8 mm. Un eje muy esbelto puede flectar.
        lambda r: ((r['x1::OSD']/2)-(r['x2::Dint']+2*r['x5::hs2'])/2) >= 3.5,
↳ # Boundarie_4: he debe ser mayor 3.5 mm. Puede romper si es muy delgado.
        # Aquí se pueden agregar más condiciones según se requiera
    ]
    return all(condition(row) for condition in boundaries)

# Función para generar muestras considerando si la variable debe ser entera
def generate_samples(n_samples):
    data = {}
    for col in X_cols:
        # Si la variable es una de las que deben ser enteras, usar randint
        if col in ['x7::Nt', 'x8::Nh']:
            low = int(np.floor(X_min[col]))
            high = int(np.ceil(X_max[col]))
            # np.random.randint es exclusivo en el extremo superior, por lo que
↳ se suma 1
            data[col] = np.random.randint(low=low, high=high+1, size=n_samples)
        else:
            data[col] = np.random.uniform(low=X_min[col], high=X_max[col],
↳ size=n_samples)
    return pd.DataFrame(data)

# Guardamos los valores máximos y mínimos
X_min = df[features].min()
X_max = df[features].max()

desired_samples = 10000
valid_samples_list = []
# Generamos muestras en bloques; para aumentar la probabilidad de cumplir las
↳ restricciones,
# se genera un bloque mayor al deseado
batch_size = int(desired_samples * 1.5)
```

```

# Acumular muestras válidas hasta obtener el número deseado
while sum(len(df_batch) for df_batch in valid_samples_list) < desired_samples:
    X_batch = generate_samples(batch_size)
    X_valid_batch = X_batch[X_batch.apply(check_boundaries, axis=1)]
    valid_samples_list.append(X_valid_batch)

# Concatenar todas las muestras válidas y truncar a desired_samples
valid_samples = pd.concat(valid_samples_list).reset_index(drop=True)
X_new = valid_samples.iloc[:desired_samples].copy()
print(f"Se generaron {len(X_new)} muestras de X que cumplen con las
↳restricciones de Boundaries B (objetivo: {desired_samples}).")
display(X_new.head())

```

Se generaron 10000 muestras de X que cumplen con las restricciones de Boundaries B (objetivo: 10000).

	x1::OSD	x2::Dint	x3::L	x4::tm	x5::hs2	x6::wt	x7::Nt \
0	57.739013	25.618727	31.781983	2.443376	10.051552	4.021307	22
1	55.701469	37.016266	33.828646	2.348957	5.623211	2.081814	22
2	48.458063	21.942572	14.966768	2.864008	9.605803	3.540775	14
3	50.679253	21.359862	14.373353	2.082497	8.610180	3.164543	16
4	59.112750	25.544342	28.039716	2.566281	10.398713	4.541243	15

	x8::Nh
0	5
1	4
2	4
3	6
4	5

```

[8]: # =====
# Paso 4.1: Generamos la matriz M de funciones de X
# =====
M_new = pd.DataFrame()
# Utilizamos los boundaries relevantes (se asume que B tiene al menos 'b11::g',
↳etc.)
M_new['m1::Drot'] = X_new['x2::Dint'] - 2 * 0.5
M_new['m2::Dsh'] = M_new['m1::Drot'] - 2 * X_new['x4::tm'] - X_new['x2::Dint'] /
↳3.5
M_new['m3::he'] = (X_new['x1::OSD'] / 2) - (X_new['x2::Dint'] + 2 * X_new['x5::
↳hs2']) / 2
M_new['m4::Rmag'] = (M_new['m1::Drot'] / 2) - 0.25 * X_new['x4::tm']
M_new['m5::Rs'] = (X_new['x2::Dint'] / 2) + X_new['x5::hs2']
# Calcular el Gross Fill Factor (GFF) como ejemplo (puede ajustarse según el
↳caso)
CS = 2 * X_new['x7::Nt'] * X_new['x8::Nh'] * np.pi * (0.51 / 2) ** 2

```

```
SS = (np.pi * M_new['m5::Rs']**2 - np.pi * (X_new['x2::Dint'] / 2)**2) / 12 -
↳X_new['x6::wt'] * X_new['x5::hs2']
M_new['m6::GFF'] = 100 * (CS / SS)
```

```
[9]: # =====
# Paso 5: Cargar modelo final desescalado y predecir
# =====
model_filename = os.path.join(modelo_path, f"DBG_descaled_unified.joblib")
print(model_filename)
loaded_model = joblib.load(model_filename)

# Predicción en la escala original
y_pred = loaded_model.predict(X_new)
```

C:\Users\s00244\Documents\GitHub\MotorDesignDataDriven\Notebooks_TFM\4.DBG\Model
os_DBG\5000_MOT_Uniforme\DBG_descaled_unified.joblib

```
[10]: # =====
# Paso 6: Escalado de datos
# =====
scaler_X = StandardScaler()
X_scaled = scaler_X.fit_transform(X_new)
scaler_Y = StandardScaler()
Y_scaled = scaler_Y.fit_transform(Y)

# Crear DataFrames escalados completos (para reentrenamiento final y
↳predicciones)
X_scaled_df = X_new
Y_scaled_df = Y
```

```
[11]: # -----
# Definir una clase que encapsule el ensemble de los mejores modelos
# -----
class BestModelEnsemble:
    def __init__(self, model_dict, outputs):
        """
        model_dict: Diccionario que mapea cada variable de salida a una tupla
↳(modelo, índice)
                    donde 'modelo' es el mejor modelo para esa salida y
↳'índice' es la posición
                    de esa salida en el vector de predicción que produce ese
↳modelo.
        outputs: Lista de nombres de variables de salida, en el orden deseado.
        """
        self.model_dict = model_dict
        self.outputs = outputs
```

```

def predict(self, X):
    """
    Realiza la predicción para cada variable de salida usando el modelo
    ↪ asignado.
    Se espera que cada modelo tenga un método predict que devuelva un array
    ↪ de
    dimensiones (n_samples, n_outputs_model). Si el modelo es univariable,
    ↪ se asume
    que devuelve un array 1D.

    :param X: Datos de entrada (array o DataFrame) con la forma (n_samples,
    ↪ n_features).
    :return: Array con la predicción para todas las variables de salida,
    ↪ forma (n_samples, n_outputs).
    """
    n_samples = X.shape[0]
    n_outputs = len(self.outputs)
    preds = np.zeros((n_samples, n_outputs))

    # Iterar sobre cada variable de salida
    for output in self.outputs:
        model, idx = self.model_dict[output]
        model_pred = model.predict(X)
        # Si el modelo es univariable, model_pred es 1D; de lo contrario,
        ↪ es 2D
        if model_pred.ndim == 1:
            preds[:, self.outputs.index(output)] = model_pred
        else:
            preds[:, self.outputs.index(output)] = model_pred[:, idx]
    return preds

```

```

[12]: # =====
# Paso 7: Preprocesar los nuevos datos con el mismo escalador usado en
    ↪ entrenamiento
# =====
# Convertir las predicciones a la escala original
preds_original = y_pred
display(preds_original[0])

# Combinar las predicciones en un DataFrame
df_predictions = pd.DataFrame(preds_original, columns=outputs)

# Combinar las variables de entrada originales y las salidas predichas
mot = pd.concat([X_new, M_new], axis=1)
motors = pd.concat([mot, df_predictions], axis=1)
display(motors.head(15))

```

```
array([8.43545788e-01, 7.88012478e+01, 1.29385826e+00, 4.02428637e+03,
       2.39351825e+02, 7.57942494e+01, 1.25718784e+01, 5.13579431e+03,
       9.15424914e+01])
```

	x1::OSD	x2::Dint	x3::L	x4::tm	x5::hs2	x6::wt	x7::Nt \
0	57.739013	25.618727	31.781983	2.443376	10.051552	4.021307	22
1	55.701469	37.016266	33.828646	2.348957	5.623211	2.081814	22
2	48.458063	21.942572	14.966768	2.864008	9.605803	3.540775	14
3	50.679253	21.359862	14.373353	2.082497	8.610180	3.164543	16
4	59.112750	25.544342	28.039716	2.566281	10.398713	4.541243	15
5	58.475943	27.493545	12.576956	2.520047	11.186401	2.869536	25
6	53.766832	21.735243	31.213946	3.241647	10.699640	2.374365	18
7	46.576302	21.536620	20.353282	2.833550	6.754147	3.372813	26
8	50.428177	25.736853	20.788893	2.788333	7.083470	3.921121	5
9	57.811825	34.456591	17.238978	2.752249	5.728449	2.745969	7
10	51.186176	23.894798	17.183530	2.369422	9.096225	2.599487	20
11	57.500903	34.090783	37.661305	2.180233	6.026680	4.689462	12
12	59.368120	21.442862	23.105132	2.998199	12.503771	2.041355	18
13	51.013443	25.540723	24.699027	2.455742	6.790719	3.277956	10
14	56.481669	26.011266	34.169712	2.418495	6.663797	4.619776	11

	x8::Nh	m1::Drot	m2::Dsh	...	m6::GFF	p1::W	p4::GFF \
0	5	24.618727	12.412338	...	84.089330	0.843546	78.801248
1	4	36.016266	20.742276	...	70.407106	0.735548	70.059653
2	4	20.942572	8.945250	...	50.478243	0.353519	54.232766
3	6	20.359862	10.092051	...	97.302792	0.446476	92.226806
4	5	24.544342	12.113396	...	60.525094	0.777579	63.702734
5	4	26.493545	13.598153	...	50.329395	0.459175	55.499953
6	5	20.735243	8.041881	...	56.181107	0.708497	59.801299
7	6	20.536620	8.716200	...	233.943794	0.543727	93.607320
8	4	24.736853	11.806800	...	24.695278	0.411649	27.707768
9	8	33.456591	18.107352	...	51.373778	0.531055	69.570716
10	9	22.894798	11.328869	...	133.909481	0.588717	99.781736
11	5	33.090783	18.990092	...	69.970224	0.905060	75.193828
12	7	20.442862	8.319933	...	60.139833	0.707649	62.586766
13	7	24.540723	12.331890	...	81.203898	0.584561	90.714838
14	3	25.011266	12.742486	...	51.423180	0.793178	58.067516

	p5::BSP_T	p6::BSP_n	p7::BSP_Pm	p8::BSP_Mu	p9::BSP_Irms \
0	1.293858	4024.286368	239.351825	75.794249	12.571878
1	0.903996	6101.978426	265.829679	80.161631	10.022244
2	0.299880	7634.670165	245.516346	87.487547	10.070279
3	0.466765	12915.206269	300.919447	85.339741	15.031529
4	0.932663	3001.326114	286.462955	83.530609	12.596004
5	0.530852	4114.537314	227.906361	80.884929	10.045504
6	0.879672	2991.585253	272.502250	80.009854	12.567975
7	0.607276	22177.981906	261.534676	75.940039	14.983005
8	0.179600	16574.423995	306.799497	90.456781	10.073510

9	0.519127	11261.947498	617.229398	91.292699	20.029477
10	0.738627	12060.728537	377.747176	80.096391	22.531423
11	1.232478	1079.488441	332.063327	85.600423	12.582260
12	0.721756	3831.221385	308.390087	80.049994	17.566057
13	0.749373	8039.110383	447.182482	89.575871	17.546973
14	0.517558	4314.623945	218.257403	88.181153	7.558288

	p10::MSP_n	p11::UWP_Mu
0	5135.794315	91.542491
1	5854.738680	78.355673
2	10470.547406	89.191287
3	16189.051025	92.264251
4	4399.805860	92.267205
5	5345.701053	90.798200
6	3870.705916	91.086400
7	22958.907362	94.421584
8	17338.902076	86.828616
9	11688.173469	89.499920
10	14513.129125	93.436966
11	1504.634046	89.814511
12	6060.280397	91.401434
13	9472.631634	93.031207
14	4848.859266	92.784853

[15 rows x 23 columns]

```
[13]: # =====
# Paso 7.1: Calculos derivados de las variables de salida (Ej: Densidad de
# potencia)
# =====
# Añadimos las columnas que queramos obtener como resultado de cálculos con las
# variables de salida.
motors['p12::BSP_wPOT'] = motors['p7::BSP_Pm']/motors['p1::W']
motors['p13::BSP_kt'] = motors['p5::BSP_T']/motors['p9::BSP_Irms']

display(motors.head(15))

# Guardar el DataFrame de los motores generados en formato CSV
model_file = os.path.join(modelo_path, "generated_motors.csv")
motors.to_csv(model_file, index=False)
print("Base de datos de 10,000 motores guardada en:", modelo_path)
```

	x1::OSD	x2::Dint	x3::L	x4::tm	x5::hs2	x6::wt	x7::Nt	\
0	57.739013	25.618727	31.781983	2.443376	10.051552	4.021307	22	
1	55.701469	37.016266	33.828646	2.348957	5.623211	2.081814	22	
2	48.458063	21.942572	14.966768	2.864008	9.605803	3.540775	14	
3	50.679253	21.359862	14.373353	2.082497	8.610180	3.164543	16	
4	59.112750	25.544342	28.039716	2.566281	10.398713	4.541243	15	

5	58.475943	27.493545	12.576956	2.520047	11.186401	2.869536	25
6	53.766832	21.735243	31.213946	3.241647	10.699640	2.374365	18
7	46.576302	21.536620	20.353282	2.833550	6.754147	3.372813	26
8	50.428177	25.736853	20.788893	2.788333	7.083470	3.921121	5
9	57.811825	34.456591	17.238978	2.752249	5.728449	2.745969	7
10	51.186176	23.894798	17.183530	2.369422	9.096225	2.599487	20
11	57.500903	34.090783	37.661305	2.180233	6.026680	4.689462	12
12	59.368120	21.442862	23.105132	2.998199	12.503771	2.041355	18
13	51.013443	25.540723	24.699027	2.455742	6.790719	3.277956	10
14	56.481669	26.011266	34.169712	2.418495	6.663797	4.619776	11

	x8::Nh	m1::Drot	m2::Dsh	...	p4::GFF	p5::BSP_T	p6::BSP_n	\
0	5	24.618727	12.412338	...	78.801248	1.293858	4024.286368	
1	4	36.016266	20.742276	...	70.059653	0.903996	6101.978426	
2	4	20.942572	8.945250	...	54.232766	0.299880	7634.670165	
3	6	20.359862	10.092051	...	92.226806	0.466765	12915.206269	
4	5	24.544342	12.113396	...	63.702734	0.932663	3001.326114	
5	4	26.493545	13.598153	...	55.499953	0.530852	4114.537314	
6	5	20.735243	8.041881	...	59.801299	0.879672	2991.585253	
7	6	20.536620	8.716200	...	93.607320	0.607276	22177.981906	
8	4	24.736853	11.806800	...	27.707768	0.179600	16574.423995	
9	8	33.456591	18.107352	...	69.570716	0.519127	11261.947498	
10	9	22.894798	11.328869	...	99.781736	0.738627	12060.728537	
11	5	33.090783	18.990092	...	75.193828	1.232478	1079.488441	
12	7	20.442862	8.319933	...	62.586766	0.721756	3831.221385	
13	7	24.540723	12.331890	...	90.714838	0.749373	8039.110383	
14	3	25.011266	12.742486	...	58.067516	0.517558	4314.623945	

	p7::BSP_Pm	p8::BSP_Mu	p9::BSP_Irms	p10::MSP_n	p11::UWP_Mu	\
0	239.351825	75.794249	12.571878	5135.794315	91.542491	
1	265.829679	80.161631	10.022244	5854.738680	78.355673	
2	245.516346	87.487547	10.070279	10470.547406	89.191287	
3	300.919447	85.339741	15.031529	16189.051025	92.264251	
4	286.462955	83.530609	12.596004	4399.805860	92.267205	
5	227.906361	80.884929	10.045504	5345.701053	90.798200	
6	272.502250	80.009854	12.567975	3870.705916	91.086400	
7	261.534676	75.940039	14.983005	22958.907362	94.421584	
8	306.799497	90.456781	10.073510	17338.902076	86.828616	
9	617.229398	91.292699	20.029477	11688.173469	89.499920	
10	377.747176	80.096391	22.531423	14513.129125	93.436966	
11	332.063327	85.600423	12.582260	1504.634046	89.814511	
12	308.390087	80.049994	17.566057	6060.280397	91.401434	
13	447.182482	89.575871	17.546973	9472.631634	93.031207	
14	218.257403	88.181153	7.558288	4848.859266	92.784853	

	p12::BSP_wPOT	p13::BSP_kt
0	283.744911	0.102917
1	361.403589	0.090199

2	694.492281	0.029779
3	673.987796	0.031052
4	368.403615	0.074044
5	496.339216	0.052845
6	384.620315	0.069993
7	481.004059	0.040531
8	745.294628	0.017829
9	1162.270103	0.025918
10	641.644882	0.032782
11	366.896419	0.097954
12	435.795475	0.041088
13	764.988636	0.042707
14	275.168384	0.068476

[15 rows x 25 columns]

Base de datos de 10,000 motores guardada en: C:\Users\s00244\Documents\GitHub\MotorDesignDataDriven\Notebooks_TFM\4.DBG\Modelos_DBG\5000_MOT_Uniforme

```
[14]: # =====
# Paso 8: Filtrar motores válidos según constraints definidos
# =====
def is_valid_motor(row):
    constraints = [
        lambda r: 0.15 <= r['p1::W'] <= 1,      # p1::W entre 0.15 y 1
        lambda r: r['p4::GFF'] >= 1 and r['p4::GFF'] <= 60,
        lambda r: r['p5::BSP_T'] >= 0.5,
        lambda r: r['p6::BSP_n'] >= 3000,
        lambda r: 85 <= r['p8::BSP_Mu'] <= 99,    # p7::BSP_Mu entre 50 y 99
        lambda r: r['p10::MSP_n'] >= 4000,
        lambda r: 80 <= r['p11::UWP_Mu'] <= 99,    # p9::UWP_Mu entre 90 y 99
        # Puedes agregar más restricciones aquí, por ejemplo:
        # lambda r: r['p4::GFF'] >= 1 and r['p4::GFF'] <= 100,
    ]
    return all(condition(row) for condition in constraints)

motors['Valid'] = motors.apply(is_valid_motor, axis=1)
valid_motors = motors[motors['Valid']]
print(f"Número de motores válidos: {len(valid_motors)}")
```

Número de motores válidos: 530

```
[15]: ##### Ordenar los motores válidos por 'p9::UWP_Mu' de menor a mayor
sorted_motors = valid_motors.sort_values(by='p8::BSP_Mu', ascending=False)
print("Motores válidos ordenados por 'p8::BSP_Mu' (de menor a mayor):")
display(sorted_motors.head(10))
```

Motores válidos ordenados por 'p8::BSP_Mu' (de menor a mayor):

x1::OSD	x2::Dint	x3::L	x4::tm	x5::hs2	x6::wt	x7::Nt	\
---------	----------	-------	--------	---------	--------	--------	---

1615	59.387769	32.169998	21.937080	3.497787	8.672517	4.697763	5
8841	51.478880	32.302844	33.164056	2.417361	5.578714	4.716446	5
1424	50.600987	23.840088	34.426025	3.436487	8.084903	4.229597	5
383	55.049440	30.597256	37.355724	2.042843	7.212628	4.760848	5
9549	52.554025	29.686380	34.654113	2.547031	6.390001	3.861166	5
8900	57.029228	27.637400	36.601265	2.304205	8.857233	4.633507	5
9973	58.870163	30.488760	30.376425	2.362576	7.838134	3.547344	5
8991	59.021062	26.502408	39.311193	3.134490	6.863629	3.623829	5
6140	56.216132	31.396114	30.315207	3.116725	6.589711	4.820198	6
1100	55.555900	26.610658	31.260201	3.336658	9.704965	4.375744	5

	x8::Nh	m1::Drot	m2::Dsh	...	p5::BSP_T	p6::BSP_n	p7::BSP_Pm	\
1615	9	31.169998	14.982997	...	0.597715	11195.409748	663.343955	
8841	7	31.302844	17.238739	...	0.668658	7397.856744	536.211651	
1424	8	22.840088	9.155660	...	0.547782	9884.953831	579.771048	
383	8	29.597256	16.769498	...	0.816518	6940.423795	601.153819	
9549	7	28.686380	15.110495	...	0.645179	8129.719165	535.173052	
8900	8	26.637400	14.132591	...	0.719547	7930.433873	596.647786	
9973	9	29.488760	16.052533	...	0.748494	9375.757817	678.355971	
8991	9	25.502408	11.661311	...	0.813600	8065.063887	656.615595	
6140	7	30.396114	15.192346	...	0.738781	6833.613261	534.567880	
1100	8	25.610658	11.334298	...	0.581282	9688.352815	592.832207	

	p8::BSP_Mu	p9::BSP_Irms	p10::MSP_n	p11::UWP_Mu	p12::BSP_wPOT	\
1615	92.859160	22.605125	12396.350201	89.860818	1090.393920	
8841	92.749580	17.599793	8070.047900	89.751990	797.205042	
1424	92.592101	20.103088	11504.130172	91.398275	878.680266	
383	92.575788	20.121891	7617.481491	89.302669	732.678578	
9549	92.542233	17.591485	8808.791234	89.350714	762.478772	
8900	92.525986	20.129900	8803.100306	90.060338	714.687571	
9973	92.501290	22.590789	10017.301319	88.739036	885.507246	
8991	92.489776	22.561825	8927.579788	91.017323	674.331372	
6140	92.487292	17.586915	7560.701930	91.022111	729.432589	
1100	92.474871	20.128094	10968.235522	89.739270	865.893383	

	p13::BSP_kt	Valid
1615	0.026442	True
8841	0.037992	True
1424	0.027249	True
383	0.040579	True
9549	0.036676	True
8900	0.035745	True
9973	0.033133	True
8991	0.036061	True
6140	0.042007	True
1100	0.028879	True

[10 rows x 26 columns]

```
[16]: # =====
# Paso 9: Calcular y representar la frontera de Pareto
# =====
# Objetivos: minimizar p1::W, maximizar p8::BSP_Mu y p9::UWP_Mu
def compute_pareto_front(df, objectives):
    is_dominated = np.zeros(len(df), dtype=bool)
    for i in range(len(df)):
        for j in range(len(df)):
            if i == j:
                continue
            dominates = True
            for obj, sense in objectives.items():
                if sense == 'min':
                    if df.iloc[j][obj] > df.iloc[i][obj]:
                        dominates = False
                        break
                elif sense == 'max':
                    if df.iloc[j][obj] < df.iloc[i][obj]:
                        dominates = False
                        break
            if dominates:
                is_dominated[i] = True
                break
    frontier = df[~is_dominated]
    return frontier

objectives = {'p1::W': 'min', 'p8::BSP_Mu': 'max', 'p12::BSP_wPOT': 'max'}
valid_motors_reset = valid_motors.reset_index(drop=True)
pareto_motors = compute_pareto_front(valid_motors_reset, objectives)
print(f"Número de motores en la frontera de Pareto: {len(pareto_motors)}")

# Representación 2D: eje X = p9, eje Y = p1
plt.figure(figsize=(12, 6))

# Motores no válidos en negro
plt.scatter(
    motors.loc[~motors['Valid'], 'p8::BSP_Mu'],
    motors.loc[~motors['Valid'], 'p1::W'],
    c='black', label='No válidos', alpha=0.6, edgecolors='none'
)

# Motores válidos (no dominados) en azul
plt.scatter(
    valid_motors['p8::BSP_Mu'],
    valid_motors['p1::W'],
    c='blue', label='Válidos', alpha=0.6, edgecolors='none'
)
```

```

# Motores en la frontera de Pareto en rojo
plt.scatter(
    pareto_motors['p8::BSP_Mu'],
    pareto_motors['p1::W'],
    c='red', label='Frontera Pareto', s=60, marker='o', edgecolors='k'
)

plt.xlabel(r'p8::\$\\mu$')
plt.ylabel('p1::W')
plt.title('Frontera de Pareto en 2D (p8 vs p1)')
plt.legend()
plt.grid(True)
plt.tight_layout()

figure_file_2d = os.path.join(figure_path, "Pareto_frontier_2D.png")
plt.savefig(figure_file_2d, dpi=1000)
print("Figura guardada en:", figure_file_2d)
plt.close()

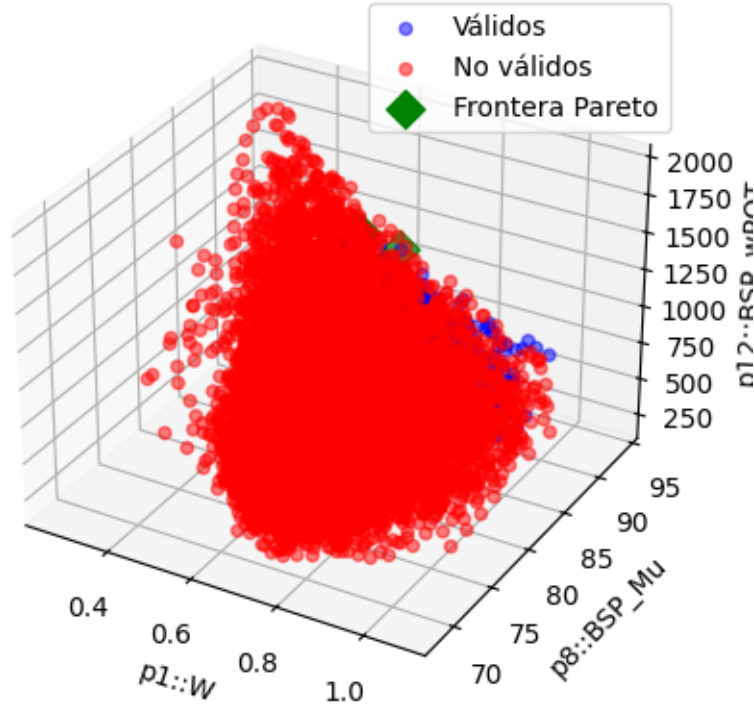
# Representación 3D de la frontera de Pareto
fig = plt.figure()
ax = fig.add_subplot(111, projection='3d')
ax.scatter(valid_motors['p1::W'], valid_motors['p8::BSP_Mu'], valid_motors['p12::BSP_wPOT'],
           c='blue', label='Válidos', alpha=0.5)
ax.scatter(motors[~motors['Valid']]['p1::W'], motors[~motors['Valid']]['p8::BSP_Mu'], motors[~motors['Valid']]['p12::BSP_wPOT'],
           c='red', label='No válidos', alpha=0.5)
ax.scatter(pareto_motors['p1::W'], pareto_motors['p8::BSP_Mu'], pareto_motors['p12::BSP_wPOT'],
           c='green', label='Frontera Pareto', s=100, marker='D')
ax.set_xlabel('p1::W')
ax.set_ylabel('p8::BSP_Mu')
ax.set_zlabel('p12::BSP_wPOT')
ax.legend()
plt.title('Frontera de Pareto de diseños de motores')
plt.show()

```

Número de motores en la frontera de Pareto: 14

Figura guardada en: C:\Users\s00244\Documents\GitHub\MotorDesignDataDriven\Notebooks_TFM\4.DBG\Figuras_DBG\5000_MOT_Uniforme\Pareto_frontier_2D.png

Frontera de Pareto de diseños de motores



```
[17]: # Si existen motores válidos, procedemos a la selección:
if len(valid_motors) > 0:
    # 1. Motor más liviano: mínimo de p1::W
    motor_liviano = valid_motors.loc[valid_motors['p1::W'].idxmin()]

    # 2. Motor más eficiente: máximo de p8::BSP_Mu (asumiendo que mayor p9::
    ↪UWP_Mu indica mayor eficiencia)
    motor_eficiente = valid_motors.loc[valid_motors['p8::BSP_Mu'].idxmax()]

    # 3. Motor más eficiente y liviano:
    # Se normalizan p1::W y p9::UWP_Mu en el subconjunto de motores válidos.
    vm = valid_motors.copy()
    # Normalizar p1::W (donde un menor valor es mejor, así que se invertirá)
    vm['p1::W_norm'] = (vm['p1::W'] - vm['p1::W'].min()) / (vm['p1::W'].max() -
    ↪vm['p1::W'].min())
    # Normalizar p8::BSP_Mu (mayor es mejor)
    vm['p8::BSP_Mu_norm'] = (vm['p8::BSP_Mu'] - vm['p8::BSP_Mu'].min()) /
    ↪(vm['p8::BSP_Mu'].max() - vm['p8::BSP_Mu'].min())
    # Normalizar p12::BSP_wPOT (mayor es mejor)
    vm['p12::BSP_wPOT_norm'] = (vm['p12::BSP_wPOT'] - vm['p12::BSP_wPOT'].
    ↪min()) / (vm['p12::BSP_wPOT'].max() - vm['p12::BSP_wPOT'].min())
```

```

# Definir un score compuesto: se busca minimizar p1::W (por ello, usamos 1_
↪ normalizado) y maximizar p8::BSP_Mu
vm['composite_score'] = (1 - vm['p1::W_norm']) + vm['p8::BSP_Mu_norm']
motor_eficiente_liviano = vm.loc[vm['composite_score'].idxmax()]

# Mostrar las soluciones:
print("\nMotor más liviano:")
print(motor_liviano)

print("\nMotor más eficiente:")
print(motor_eficiente)

print("\nMotor más eficiente y liviano (score compuesto):")
print(motor_eficiente_liviano)

# Opcional: Guardar cada solución en un CSV separado
#motor_liviano.to_frame().T.to_csv("motor_mas_liviano.csv", index=False)
# motor_eficiente.to_frame().T.to_csv("motor_mas_eficiente.csv",
↪ index=False)
# motor_eficiente_liviano.to_frame().T.to_csv("motor_eficiente_y_liviano.
↪ csv", index=False)
# print("\nSoluciones guardadas en CSV.")
else:
    print("No se encontraron motores válidos. Verifique las constraints y el_
↪ escalado de los datos.")

```

Motor más liviano:

x1::OSD	57.900295
x2::Dint	36.680621
x3::L	14.242181
x4::tm	2.096105
x5::hs2	6.5074
x6::wt	3.52096
x7::Nt	20
x8::Nh	3
m1::Drot	35.680621
m2::Dsh	21.008234
m3::he	4.102436
m4::Rmag	17.316284
m5::Rs	24.847711
m6::GFF	48.384891
p1::W	0.452416
p4::GFF	59.386588
p5::BSP_T	0.506027
p6::BSP_n	3737.274277

```

p7::BSP_Pm      211.375358
p8::BSP_Mu      85.130921
p9::BSP_Irms    7.525288
p10::MSP_n      4526.839019
p11::UWP_Mu     89.502812
p12::BSP_wPOT   467.214853
p13::BSP_kt     0.067244
Valid           True
Name: 820, dtype: object

```

Motor más eficiente:

```

x1::OSD      59.387769
x2::Dint     32.169998
x3::L        21.93708
x4::tm       3.497787
x5::hs2      8.672517
x6::wt       4.697763
x7::Nt       5
x8::Nh       9
m1::Drot     31.169998
m2::Dsh      14.982997
m3::he       4.936369
m4::Rmag     14.710552
m5::Rs       24.757516
m6::GFF      35.36341
p1::W        0.608353
p4::GFF      42.142787
p5::BSP_T    0.597715
p6::BSP_n    11195.409748
p7::BSP_Pm   663.343955
p8::BSP_Mu   92.85916
p9::BSP_Irms 22.605125
p10::MSP_n   12396.350201
p11::UWP_Mu  89.860818
p12::BSP_wPOT 1090.39392
p13::BSP_kt  0.026442
Valid        True
Name: 1615, dtype: object

```

Motor más eficiente y liviano (score compuesto):

```

x1::OSD      53.531872
x2::Dint     27.089571
x3::L        21.479058
x4::tm       2.081564
x5::hs2      9.469086
x6::wt       3.831137
x7::Nt       6
x8::Nh       9

```



```

m1::Drot                26.089571
m2::Dsh                 14.186566
m3::he                  3.752064
m4::Rmag                12.524395
m5::Rs                  23.013871
m6::GFF                 40.59213
p1::W                   0.512947
p4::GFF                 45.135671
p5::BSP_T               0.541446
p6::BSP_n               10855.906628
p7::BSP_Pm              617.63368
p8::BSP_Mu              91.845708
p9::BSP_Irms            22.615686
p10::MSP_n              13048.107926
p11::UWP_Mu             90.22314
p12::BSP_wPOT           1204.089531
p13::BSP_kt             0.023941
Valid                   True
p1::W_norm              0.116112
p8::BSP_Mu_norm         0.870718
p12::BSP_wPOT_norm      0.982633
composite_score         1.754606
Name: 2956, dtype: object

```

```

[19]: # =====
# Paso 10: Seleccionar el motor válido óptimo
# =====
# Se normalizan los objetivos y se define un score compuesto
valid_motors_comp = valid_motors.copy()
for col, sense in [('p1::W', 'min'), ('p8::BSP_Mu', 'max'), ('p12::BSP_wPOT', 'max')]:
    col_min = valid_motors_comp[col].min()
    col_max = valid_motors_comp[col].max()
    if sense == 'min':
        valid_motors_comp[col + '_norm'] = 1 - (valid_motors_comp[col] -
        col_min) / (col_max - col_min)
    else:
        valid_motors_comp[col + '_norm'] = (valid_motors_comp[col] - col_min) /
        (col_max - col_min)

valid_motors_comp['composite_score'] = (valid_motors_comp['p1::W_norm'] +
                                         valid_motors_comp['p8::BSP_Mu_norm'] +
                                         valid_motors_comp['p12::BSP_wPOT_norm'])
optimal_motor = valid_motors_comp.loc[valid_motors_comp['composite_score'].
idxmax()]
print("Motor válido óptimo (según score compuesto):")

```

```
print(optimal_motor)

model_file = os.path.join(modelo_path, "optimal_motor.csv")
optimal_motor.to_frame().T.to_csv(model_file, index=False)
print("El motor óptimo se ha guardado en:", modelo_path)
```

Motor válido óptimo (según score compuesto):

x1::OSD	53.531872
x2::Dint	27.089571
x3::L	21.479058
x4::tm	2.081564
x5::hs2	9.469086
x6::wt	3.831137
x7::Nt	6
x8::Nh	9
m1::Drot	26.089571
m2::Dsh	14.186566
m3::he	3.752064
m4::Rmag	12.524395
m5::Rs	23.013871
m6::GFF	40.59213
p1::W	0.512947
p4::GFF	45.135671
p5::BSP_T	0.541446
p6::BSP_n	10855.906628
p7::BSP_Pm	617.63368
p8::BSP_Mu	91.845708
p9::BSP_Irms	22.615686
p10::MSP_n	13048.107926
p11::UWP_Mu	90.22314
p12::BSP_wPOT	1204.089531
p13::BSP_kt	0.023941
Valid	True
p1::W_norm	0.883888
p8::BSP_Mu_norm	0.870718
p12::BSP_wPOT_norm	0.982633
composite_score	2.737238

Name: 2956, dtype: object

El motor óptimo se ha guardado en: C:\Users\s00244\Documents\GitHub\MotorDesignD
ataDriven\Notebooks_TFM\4.DBG\Modelos_DBG\5000_MOT_Uniforme

[]: