

DBG_V5

May 22, 2025

```
[1]: # Librerías necesarias
import os
import re # Import the regular expression module

import pandas as pd
import numpy as np
import math
from math import ceil

import matplotlib
#matplotlib.use('TKAgg')
import matplotlib.pyplot as plt
from matplotlib.ticker import ScalarFormatter
import seaborn as sns
from mpl_toolkits.mplot3d import Axes3D

import time
import warnings
warnings.filterwarnings("ignore")

# Para guardar y cargar modelos
import joblib

# Librerías de preprocesado y modelado de scikit-learn
from sklearn.model_selection import train_test_split, KFold, cross_val_predict,
    GridSearchCV, cross_val_score
from sklearn import model_selection
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline
from sklearn import set_config
from sklearn.metrics import mean_squared_error, r2_score
from sklearn.linear_model import LinearRegression
from sklearn.cross_decomposition import PLSRegression
from sklearn.gaussian_process import GaussianProcessRegressor
from sklearn.gaussian_process.kernels import RBF, WhiteKernel, ConstantKernel,
    as C
```

```

from sklearn.svm import SVR
from sklearn.multioutput import MultiOutputRegressor
from sklearn.ensemble import RandomForestRegressor
from sklearn.neural_network import MLPRegressor

import keras
from keras.layers import Dense
from keras.models import Sequential

import tensorflow as tf
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

from scikeras.wrappers import KerasRegressor
from sklearn.base import BaseEstimator, RegressorMixin

from skopt import BayesSearchCV
from skopt.space import Real, Integer, Categorical

import time
import warnings
warnings.filterwarnings("ignore")

# Para guardar y cargar modelos
import joblib

```

```

[2]: # Clase auxiliar que convierte un diccionario en un objeto con atributos.
class TagBunch:
    def __init__(self, d):
        self.__dict__.update(d)

# Monkey-patch: asignar __sklearn_tags__ al wrapper para evitar el error
# Definición del wrapper personalizado para KerasRegressor
class MyKerasRegressorWrapper(BaseEstimator, RegressorMixin):
    def __init__(self, model, hidden_layer_size=50, hidden_layer_size_2=3,
↳ epochs=100, **kwargs):
        """
        model: función que construye el modelo (por ejemplo, create_model)
        hidden_layer_size, hidden_layer_size_2, epochs: parámetros a pasar a la
↳ función
        kwargs: otros parámetros (como batch_size, verbose, etc.)
        """
        self.model = model
        self.hidden_layer_size = hidden_layer_size
        self.hidden_layer_size_2 = hidden_layer_size_2
        self.epochs = epochs

```

```

self.kwargs = kwargs
self.estimator_ = None # Se llenará al entrenar

def fit(self, X, y, **fit_params):
    # Se crea la instancia interna de KerasRegressor usando scikeras.
    self.estimator_ = KerasRegressor(
        model=self.model,
        hidden_layer_size=self.hidden_layer_size,
        hidden_layer_size_2=self.hidden_layer_size_2,
        epochs=self.epochs,
        **self.kwargs
    )
    self.estimator_.fit(X, y, **fit_params)
    return self

def predict(self, X):
    return self.estimator_.predict(X)

def score(self, X, y):
    return self.estimator_.score(X, y)

def get_params(self, deep=True):
    params = {
        "model": self.model,
        "hidden_layer_size": self.hidden_layer_size,
        "hidden_layer_size_2": self.hidden_layer_size_2,
        "epochs": self.epochs,
    }
    params.update(self.kwargs)
    return params

def set_params(self, **parameters):
    for key, value in parameters.items():
        setattr(self, key, value)
    return self

def __sklearn_tags__(self):
    # NUEVO: Devolver un objeto TagBunch en lugar de un dict.
    return TagBunch({
        "requires_fit": True,
        "X_types": ["2darray"],
        "preserves_dtype": [np.float64],
        "allow_nan": False,
        "requires_y": True,
    })

def __sklearn_is_fitted__(self):

```

```
return self.estimator_ is not None
```

```
[3]: # =====  
# Definición de un wrapper para desescalar la predicción del target  
# =====  
from sklearn.base import BaseEstimator, RegressorMixin  
from sklearn.metrics import r2_score  
  
class DescaledRegressor(BaseEstimator, RegressorMixin):  
    """  
    Wrapper para un modelo cuya salida se entrenó sobre y escalado y que,  
    al predecir, se desescala automáticamente usando el target_scaler.  
    """  
    def __init__(self, estimator, target_scaler):  
        self.estimator = estimator # Modelo previamente entrenado (pipeline)  
        self.target_scaler = target_scaler # Escalador entrenado sobre y_train  
  
    def predict(self, X):  
        # Se predice en la escala del target (y escalado)  
        y_pred_scaled = self.estimator.predict(X)  
        # Se aplica la transformación inversa para recuperar la escala original  
        return self.target_scaler.inverse_transform(y_pred_scaled)  
  
    def fit(self, X, y):  
        # Aunque el modelo ya esté entrenado, este método permite reentrenarlo  
        y_scaled = self.target_scaler.transform(y)  
        self.estimator.fit(X, y_scaled)  
        return self  
  
    def score(self, X, y):  
        # Calcula  $R^2$  usando las predicciones ya desescaladas  
        y_pred = self.predict(X)  
        return r2_score(y, y_pred)  
  
class SingleOutputDescaledRegressor(BaseEstimator, RegressorMixin):  
    """  
    Wrapper para obtener la predicción de un modelo multioutput  
    para una variable de salida particular y desescalarla usando el  
    target_scaler. Se utiliza el índice de la columna deseada.  
    """  
    def __init__(self, estimator, target_scaler, col_index):  
        self.estimator = estimator # Modelo multioutput previamente  
        ↪ entrenado  
        self.target_scaler = target_scaler # Escalador entrenado sobre  
        ↪ y_train  
        self.col_index = col_index # Índice de la variable de salida
```

```

def predict(self, X):
    # Se predice con el modelo multioutput; se obtiene la predicción en
    ↪escala (2D array)
    y_pred_scaled = self.estimator.predict(X)
    # Se extrae la predicción para la columna de interés
    single_pred_scaled = y_pred_scaled[:, self.col_index]
    # Se recuperan los parámetros del escalador para la columna
    scale_val = self.target_scaler.scale_[self.col_index]
    mean_val = self.target_scaler.mean_[self.col_index]
    # Desescalar manualmente: valor original = valor escalado * escala +
    ↪media
    y_pred_original = single_pred_scaled * scale_val + mean_val
    return y_pred_original

def fit(self, X, y):
    # (Opcional) Si se desea reentrenar el modelo, se transforma y y se
    ↪ajusta
    y_scaled = self.target_scaler.transform(y)
    self.estimator.fit(X, y_scaled)
    return self

def score(self, X, y):
    from sklearn.metrics import r2_score
    y_pred = self.predict(X)
    return r2_score(y, y_pred)

class UnifiedDescaledRegressor(BaseEstimator, RegressorMixin):
    """
    Modelo que encapsula un diccionario de modelos individuales (por variable
    ↪de salida).
    Cada modelo (del tipo SingleOutputDescaledRegressor) se utiliza para
    ↪predecir su variable
    de salida correspondiente y se realiza la transformación inversa para
    ↪retornar el valor original.
    """
    def __init__(self, models):
        """
        :param models: diccionario con llave = etiqueta de salida y valor =
        ↪SingleOutputDescaledRegressor.
        """
        self.models = models
        # Se conserva el orden de salida en función de las claves del
        ↪diccionario;
        # se asume que estas claves son exactamente las mismas que aparecen en
        ↪y_test.
        self.output_columns = list(models.keys())

```

```

def predict(self, X):
    preds = []
    # Se predice para cada variable en el orden de self.output_columns
    for col in self.output_columns:
        model = self.models[col]
        pred = model.predict(X) # cada predicción es un array de forma
↪(n_samples,)
        preds.append(pred)
    # Se combinan las predicciones columna a columna para formar un array
↪(n_samples, n_targets)
    return np.column_stack(preds)

def score(self, X, y):
    from sklearn.metrics import r2_score
    y_pred = self.predict(X)
    return r2_score(y, y_pred, multioutput='uniform_average')

```

```

[4]: # =====
# 1. CARGA DE DATOS Y PREPARACIÓN DEL DATAFRAME
# =====
# Definir las rutas base y de las carpetas
base_path = os.getcwd() # Se asume que el notebook se ejecuta desde la carpeta
↪'DBG'
db_path = os.path.join(base_path, "DB_DBG")
fig_path = os.path.join(base_path, "Figuras_DBG")
model_path = os.path.join(base_path, "Modelos_DBG")

# Ruta al archivo de la base de datos
data_file = os.path.join(db_path, "design_DB_preprocessed_1000_Uniforme.csv")
print(data_file)

# Ruta al archivo de las figuras
figure_path = os.path.join(fig_path, "1000_MOT_Uniforme")
print(figure_path)

# Ruta al archivo de los modelos
modelo_path = os.path.join(model_path, "1000_MOT_Uniforme")
print(modelo_path)

# Lectura del archivo CSV
try:
    df = pd.read_csv(data_file)
    print("Archivo cargado exitosamente.")
except FileNotFoundError:
    print("Error: Archivo no encontrado. Revisa la ruta del archivo.")
except pd.errors.ParserError:

```

```

    print("Error: Problema al analizar el archivo CSV. Revisa el formato del_
↪archivo.")
except Exception as e:
    print(f"Ocurrió un error inesperado: {e}")

# Función para limpiar nombres de archivo inválidos
def clean_filename(name):
    return re.sub(r'[\\"/*?:"<>|]', "_", name)

```

C:\Users\s00244\Documents\GitHub\MotorDesignDataDriven\Notebooks_TFM\4.DBG\DB_DB
G\design_DB_preprocessed_1000_Uniforme.csv
C:\Users\s00244\Documents\GitHub\MotorDesignDataDriven\Notebooks_TFM\4.DBG\Figuras_DBG\1000_MOT_Uniforme
C:\Users\s00244\Documents\GitHub\MotorDesignDataDriven\Notebooks_TFM\4.DBG\Modelos_DBG\1000_MOT_Uniforme
Archivo cargado exitosamente.

```

[5]: # =====
# 2. SEPARACIÓN DE VARIABLES
# =====
# Se separan las columnas según prefijos:
# - Variables 'x' (inputs principales)
# - Variables 'm' (otras características del motor)
# - Variables 'p' (salidas: parámetros a predecir)
X_cols = [col for col in df.columns if col.startswith('x')]
M_cols = [col for col in df.columns if col.startswith('m')]
P_cols = [col for col in df.columns if col.startswith('p')]

# Se crea el DataFrame de características y del target. En este ejemplo se usa_
↪X (inputs)
# y P (salidas), pero se pueden incluir también las M si así se requiere.
X = df[X_cols].copy()
M = df[M_cols].copy()
P = df[P_cols].copy()
y = df[P_cols].copy() # Usamos las columnas p para las predicciones

# Convertir todas las columnas a tipo numérico en caso de haber algún dato no_
↪numérico
for col in X.columns:
    X[col] = pd.to_numeric(X[col], errors='coerce')
for col in M.columns:
    M[col] = pd.to_numeric(M[col], errors='coerce')
for col in P.columns:
    P[col] = pd.to_numeric(P[col], errors='coerce')
for col in y.columns:
    y[col] = pd.to_numeric(y[col], errors='coerce')

```

```

# Concatena las matrices X y M
X_M = pd.concat([X, M], axis=1)

print("\nPrimeras filas de X:")
display(X.head())
print("\nPrimeras filas de y (P):")
display(y.head())

print("Columnas de salida originales:", y.columns.tolist())

# Definir un umbral para la varianza
threshold = 1e-8 # Este umbral puede ajustarse según la precisión deseada

# Calcular la varianza de cada columna del DataFrame y
variances = y.var()
print("\nVariancia de cada columna de salida:")
print(variances)

# Seleccionar aquellas columnas cuya varianza es mayor que el umbral
cols_to_keep = variances[variances > threshold].index
y = y[cols_to_keep]

# Filtrar las filas del DataFrame y para eliminar aquellas que contienen NaN
Y = y.dropna() # Se eliminan todas las filas con al menos un valor NaN en y
# Actualizar X para que quede alineado con los índices de y
X = X.loc[Y.index]

features = list(X.columns)
outputs = [col for col in Y.columns]

print("\nColumnas de salida tras eliminar las constantes o casi constantes:")
print(Y.columns.tolist())

```

Primeras filas de X:

	x1::OSD	x2::Dint	x3::L	x4::tm	x5::hs2	x6::wt	x7::Nt	x8::Nh
0	48.60	27.8640	14.800000	2.780311	6.312467	4.392325	6	4
1	59.40	24.0560	29.200000	2.121244	10.249868	2.569301	12	3
2	54.72	32.0528	22.960001	2.456926	7.797124	2.123813	18	3
3	48.84	21.9616	25.120000	3.032072	6.972909	2.557345	14	3
4	59.76	27.1024	29.680002	3.249535	8.141503	4.802138	10	3

Primeras filas de y (P):

	p1::W	p2::Tnom	p3::nnom	p4::GFF	p5::BSP_T	p6::BSP_n	p7::BSP_Pm	\
0	0.322074	0.11	3960.0	40.082718	0.170606	17113.2340	305.74252	

1	0.674799	0.11	3960.0	24.675780	0.412852	4913.5480	212.43124
2	0.535554	0.11	3960.0	42.652370	0.538189	3806.5370	214.53262
3	0.487619	0.11	3960.0	57.017277	0.380920	5161.0967	205.87508
4	0.749844	0.11	3960.0	37.444870	0.429127	4961.4146	222.95651

	p8::BSP_Mu	p9::BSP_Irms	p10::MSP_n	p11::UWP_Mu
0	90.763855	10.070335	18223.3200	86.138150
1	87.076820	7.558135	5737.1406	88.799880
2	83.929474	7.553457	4325.1235	83.402340
3	87.040310	7.554095	6293.4336	91.343490
4	89.363690	7.554099	5615.5110	91.807846

Columnas de salida originales: ['p1::W', 'p2::Tnom', 'p3::nnom', 'p4::GFF', 'p5::BSP_T', 'p6::BSP_n', 'p7::BSP_Pm', 'p8::BSP_Mu', 'p9::BSP_Irms', 'p10::MSP_n', 'p11::UWP_Mu']

Variancia de cada columna de salida:

p1::W	2.413512e-02
p2::Tnom	1.928477e-34
p3::nnom	0.000000e+00
p4::GFF	1.228099e+02
p5::BSP_T	5.206690e-02
p6::BSP_n	2.567653e+07
p7::BSP_Pm	1.719746e+04
p8::BSP_Mu	6.758214e+00
p9::BSP_Irms	2.226090e+01
p10::MSP_n	3.054785e+07
p11::UWP_Mu	1.010653e+01

dtype: float64

Columnas de salida tras eliminar las constantes o casi constantes:

['p1::W', 'p4::GFF', 'p5::BSP_T', 'p6::BSP_n', 'p7::BSP_Pm', 'p8::BSP_Mu', 'p9::BSP_Irms', 'p10::MSP_n', 'p11::UWP_Mu']

```
[6]: # =====
# Paso 3: Definir el modelo ANN_K para que pueda leerse
# =====
import json

# Supongamos que el JSON está en la raíz del proyecto y se llama
↳ 'hiperparametros_MOP.json'
params_file = os.path.join(modelo_path, "hiperparametros_DBG.json")
try:
    with open(params_file, "r") as f:
        hiperparametros = json.load(f)
    print(f"Hiperparámetros cargados desde {params_file}")
except FileNotFoundError:
    print(f"No se encontró el archivo de hiperparámetros: {params_file}")
```

```

param_grids = {}

# Asegurarnos de tener diccionario con cada modelo
hiperparametros = {
    "PLS": hiperparametros.get("PLS", {}),
    "LR": hiperparametros.get("LR", {}),
    "GPR": hiperparametros.get("GPR", {}),
    "SVR": hiperparametros.get("SVR", {}),
    "RF": hiperparametros.get("RF", {}),
    "ANN": hiperparametros.get("ANN", {}),
    "ANN-K": hiperparametros.get("ANN-K", {}),
}

akk_par = hiperparametros['ANN-K']
bs = akk_par.get('model__batch_size')
h1 = akk_par.get('model__hidden_layer_size')
h2 = akk_par.get('model__hidden_layer_size_2')
ep = akk_par.get('model__epochs')

n_cols = X.shape[1]
n_out = y.shape[1] # El modelo debe producir n_out salidas

# Definir la función que crea el modelo Keras
# @tf.function(reduce_retracing=True)
def ANN_K_model(hidden_layer_size=h1, hidden_layer_size_2=h2):
    model = Sequential()
    model.add(Dense(hidden_layer_size, activation='relu',
        ↪input_shape=(n_cols,)))
    model.add(Dense(hidden_layer_size_2, activation='relu'))
    model.add(Dense(n_out))
    model.compile(loss='mean_squared_error', optimizer='adam')
    return model

# Envolver el modelo en KerasRegressor para utilizarlo con scikit-learn
my_keras_reg = MyKerasRegressorWrapper(
    model=ANN_K_model,
    hidden_layer_size=h1,
    hidden_layer_size_2=h2,
    epochs=ep,
    random_state=42,
    verbose=0
)

```

Hiperparámetros cargados desde C:\Users\s00244\Documents\GitHub\MotorDesignDataD riven\Notebooks_TFM\4.DBG\Modelos_DBG\1000_MOT_Uniforme\hiperparametros_DBG.json

```
[7]: # =====
# Paso 4: Generar 10,000 nuevos motores a partir de los rangos de entrada
# =====
# Las restricciones (Boundaries B) se definen sobre las variables de X y de M.
# Definir la función check_boundaries escalable: se evalúan todas las
↳ condiciones definidas en una lista.
def check_boundaries(row):
    boundaries = [
        lambda r: r['x1::OSD'] > r['x2::Dint'], # Boundarie_1: x1 debe ser
↳ mayor que x2
        lambda r: 45.0 < r['x1::OSD'] < 60.0, # Boundarie_2: x1 debe
↳ estar entre 45 y 60.
        lambda r: ((r['x2::Dint']-2*0.5)-2*r['x4::tm']-r['x2::Dint']/3.5) >= 8,
↳ # Boundarie_3: Dsh debe ser mayor 8 mm. Un eje muy esbelto puede flectar.
        lambda r: ((r['x1::OSD']/2)-(r['x2::Dint']+2*r['x5::hs2'])/2) >= 3.5,
↳ # Boundarie_4: he debe ser mayor 3.5 mm. Puede romper si es muy delgado.
        # Aquí se pueden agregar más condiciones según se requiera
    ]
    return all(condition(row) for condition in boundaries)

# Función para generar muestras considerando si la variable debe ser entera
def generate_samples(n_samples):
    data = {}
    for col in X_cols:
        # Si la variable es una de las que deben ser enteras, usar randint
        if col in ['x7::Nt', 'x8::Nh']:
            low = int(np.floor(X_min[col]))
            high = int(np.ceil(X_max[col]))
            # np.random.randint es exclusivo en el extremo superior, por lo que
↳ se suma 1
            data[col] = np.random.randint(low=low, high=high+1, size=n_samples)
        else:
            data[col] = np.random.uniform(low=X_min[col], high=X_max[col],
↳ size=n_samples)
    return pd.DataFrame(data)

# Guardamos los valores máximos y mínimos
X_min = df[features].min()
X_max = df[features].max()

desired_samples = 10000
valid_samples_list = []
# Generamos muestras en bloques; para aumentar la probabilidad de cumplir las
↳ restricciones,
# se genera un bloque mayor al deseado
batch_size = int(desired_samples * 1.5)
```

```

# Acumular muestras válidas hasta obtener el número deseado
while sum(len(df_batch) for df_batch in valid_samples_list) < desired_samples:
    X_batch = generate_samples(batch_size)
    X_valid_batch = X_batch[X_batch.apply(check_boundaries, axis=1)]
    valid_samples_list.append(X_valid_batch)

# Concatenar todas las muestras válidas y truncar a desired_samples
valid_samples = pd.concat(valid_samples_list).reset_index(drop=True)
X_new = valid_samples.iloc[:desired_samples].copy()
print(f"Se generaron {len(X_new)} muestras de X que cumplen con las
↳restricciones de Boundaries B (objetivo: {desired_samples}).")
display(X_new.head())

```

Se generaron 10000 muestras de X que cumplen con las restricciones de Boundaries B (objetivo: 10000).

	x1::OSD	x2::Dint	x3::L	x4::tm	x5::hs2	x6::wt	x7::Nt \
0	59.109233	31.737597	31.857104	3.038212	8.100607	2.862901	19
1	59.328662	25.186221	36.345354	3.184483	5.897683	2.917327	10
2	56.160596	27.553930	15.929237	2.550499	8.694059	4.861692	29
3	57.901684	31.469801	28.003841	2.484687	7.803684	4.070863	5
4	57.872131	28.719523	22.667203	3.251350	6.544124	2.336454	20

	x8::Nh
0	9
1	5
2	6
3	4
4	8

```

[8]: # =====
# Paso 4.1: Generamos la matriz M de funciones de X
# =====
M_new = pd.DataFrame()
# Utilizamos los boundaries relevantes (se asume que B tiene al menos 'b11::g',
↳etc.)
M_new['m1::Drot'] = X_new['x2::Dint'] - 2 * 0.5
M_new['m2::Dsh'] = M_new['m1::Drot'] - 2 * X_new['x4::tm'] - X_new['x2::Dint'] /
↳3.5
M_new['m3::he'] = (X_new['x1::OSD'] / 2) - (X_new['x2::Dint'] + 2 * X_new['x5::
↳hs2']) / 2
M_new['m4::Rmag'] = (M_new['m1::Drot'] / 2) - 0.25 * X_new['x4::tm']
M_new['m5::Rs'] = (X_new['x2::Dint'] / 2) + X_new['x5::hs2']
# Calcular el Gross Fill Factor (GFF) como ejemplo (puede ajustarse según el
↳caso)
CS = 2 * X_new['x7::Nt'] * X_new['x8::Nh'] * np.pi * (0.51 / 2) ** 2

```

```
SS = (np.pi * M_new['m5::Rs']**2 - np.pi * (X_new['x2::Dint'] / 2)**2) / 12 -
↳X_new['x6::wt'] * X_new['x5::hs2']
M_new['m6::GFF'] = 100 * (CS / SS)
```

```
[9]: # =====
# Paso 5: Cargar modelo final desescalado y predecir
# =====
model_filename = os.path.join(modelo_path, f"DBG_descaled_unified.joblib")
print(model_filename)
loaded_model = joblib.load(model_filename)

# Predicción en la escala original
y_pred = loaded_model.predict(X_new)
```

C:\Users\s00244\Documents\GitHub\MotorDesignDataDriven\Notebooks_TFM\4.DBG\Model
os_DBG\1000_MOT_Uniforme\DBG_descaled_unified.joblib

```
[10]: # =====
# Paso 6: Escalado de datos
# =====
scaler_X = StandardScaler()
X_scaled = scaler_X.fit_transform(X_new)
scaler_Y = StandardScaler()
Y_scaled = scaler_Y.fit_transform(Y)

# Crear DataFrames escalados completos (para reentrenamiento final y
↳predicciones)
X_scaled_df = X_new
Y_scaled_df = Y
```

```
[11]: # -----
# Definir una clase que encapsule el ensemble de los mejores modelos
# -----
class BestModelEnsemble:
    def __init__(self, model_dict, outputs):
        """
        model_dict: Diccionario que mapea cada variable de salida a una tupla
↳(modelo, índice)
                    donde 'modelo' es el mejor modelo para esa salida y
↳'índice' es la posición
                    de esa salida en el vector de predicción que produce ese
↳modelo.
        outputs: Lista de nombres de variables de salida, en el orden deseado.
        """
        self.model_dict = model_dict
        self.outputs = outputs
```

```

def predict(self, X):
    """
    Realiza la predicción para cada variable de salida usando el modelo
    ↪ asignado.
    Se espera que cada modelo tenga un método predict que devuelva un array
    ↪ de
    dimensiones (n_samples, n_outputs_model). Si el modelo es univariable,
    ↪ se asume
    que devuelve un array 1D.

    :param X: Datos de entrada (array o DataFrame) con la forma (n_samples,
    ↪ n_features).
    :return: Array con la predicción para todas las variables de salida,
    ↪ forma (n_samples, n_outputs).
    """
    n_samples = X.shape[0]
    n_outputs = len(self.outputs)
    preds = np.zeros((n_samples, n_outputs))

    # Iterar sobre cada variable de salida
    for output in self.outputs:
        model, idx = self.model_dict[output]
        model_pred = model.predict(X)
        # Si el modelo es univariable, model_pred es 1D; de lo contrario,
        ↪ es 2D
        if model_pred.ndim == 1:
            preds[:, self.outputs.index(output)] = model_pred
        else:
            preds[:, self.outputs.index(output)] = model_pred[:, idx]
    return preds

```

```

[12]: # =====
# Paso 7: Preprocesar los nuevos datos con el mismo escalador usado en
    ↪ entrenamiento
# =====
# Convertir las predicciones a la escala original
preds_original = y_pred
display(preds_original[0])

# Combinar las predicciones en un DataFrame
df_predictions = pd.DataFrame(preds_original, columns=outputs)

# Combinar las variables de entrada originales y las salidas predichas
mot = pd.concat([X_new, M_new], axis=1)
motors = pd.concat([mot, df_predictions], axis=1)
display(motors.head(15))

```

```
array([ 1.07234973, 121.68340057, 2.19548776, -899.79023511,
        455.8755681, 80.37661502, 22.62517856, 414.86152757,
        88.6456328 ])
```

	x1::OSD	x2::Dint	x3::L	x4::tm	x5::hs2	x6::wt	x7::Nt	\
0	59.109233	31.737597	31.857104	3.038212	8.100607	2.862901	19	
1	59.328662	25.186221	36.345354	3.184483	5.897683	2.917327	10	
2	56.160596	27.553930	15.929237	2.550499	8.694059	4.861692	29	
3	57.901684	31.469801	28.003841	2.484687	7.803684	4.070863	5	
4	57.872131	28.719523	22.667203	3.251350	6.544124	2.336454	20	
5	52.032954	25.642214	19.145558	3.351096	8.292027	4.708284	10	
6	59.022678	30.102536	20.725107	3.232948	8.300313	4.880363	26	
7	59.084247	23.506281	33.429104	2.176902	12.881647	3.738299	10	
8	59.755479	29.172891	20.501322	2.071435	7.684031	2.163283	30	
9	58.495452	23.956231	22.701931	3.328490	13.620656	2.710177	29	
10	54.892270	27.079011	32.339341	3.050077	8.790003	2.443443	8	
11	59.557619	29.147132	17.652638	3.129924	5.193074	2.318498	17	
12	55.110892	26.975004	33.937222	2.244937	6.909910	4.422841	11	
13	56.524556	32.208991	22.513839	3.210961	8.131219	3.047029	29	
14	57.114990	33.602851	32.270730	2.398497	6.025044	3.636245	15	

	x8::Nh	m1::Drot	m2::Dsh	...	m6::GFF	p1::W	p4::GFF	\
0	9	30.737597	15.593288	...	113.980694	1.072350	121.683401	
1	5	24.186221	10.621192	...	66.350372	0.949640	79.164804	
2	6	26.553930	13.580381	...	176.682147	0.663990	118.831479	
3	4	30.469801	16.509056	...	16.859131	0.633743	18.483142	
4	8	27.719523	13.011245	...	144.863821	0.831519	129.987080	
5	9	24.642214	10.613676	...	106.197637	0.551859	94.679272	
6	7	29.102536	14.035915	...	173.162736	0.833932	126.125566	
7	3	22.506281	11.436397	...	16.439126	0.696591	17.571305	
8	9	28.172891	15.694910	...	191.776137	0.950668	133.769191	
9	9	22.956231	9.454615	...	109.842356	0.909935	100.507478	
10	4	26.079011	12.241997	...	21.410224	0.635098	24.593303	
11	7	28.147132	13.559531	...	140.327589	0.680010	124.018366	
12	9	25.975004	13.777985	...	131.594558	0.920568	115.591728	
13	3	31.208991	15.584499	...	58.177074	0.626660	69.087639	
14	7	32.602851	18.205043	...	105.666676	0.935673	111.126049	

	p5::BSP_T	p6::BSP_n	p7::BSP_Pm	p8::BSP_Mu	p9::BSP_Irms	\
0	2.195488	-899.790235	455.875568	80.376615	22.625179	
1	0.786514	3929.156938	355.540030	89.221634	12.580649	
2	0.990222	3.527924	198.335769	77.244850	14.958926	
3	0.303060	9698.199115	304.440999	89.972861	10.057482	
4	1.267237	1118.107567	416.918003	80.546046	20.088639	
5	0.730050	6639.036286	525.634760	90.026268	22.623560	
6	1.472640	-1020.992272	258.078796	78.270538	17.490562	
7	0.391729	5171.823947	211.433877	87.473022	7.568995	
8	1.050829	-1929.044073	259.761539	75.457806	22.323881	

9	1.150322	-1405.642051	246.165757	73.158322	22.359127
10	0.446300	6355.251622	300.436897	88.765449	10.057775
11	0.843218	3236.366880	433.204842	85.452662	17.581354
12	1.467850	2610.183051	498.616377	87.017205	22.637501
13	0.942382	599.422861	187.331615	77.982601	7.592398
14	1.828527	1134.229564	426.674349	84.610137	17.626277

	p10::MSP_n	p11::UWP_Mu
0	414.861528	88.645633
1	4947.391460	92.228441
2	3205.291516	95.466488
3	10232.612990	87.166049
4	3684.173703	90.843749
5	9849.559652	93.973760
6	1889.461643	94.751823
7	6103.216045	88.430043
8	1083.331967	89.947109
9	1565.227176	91.293506
10	6908.425001	85.906202
11	5973.476339	91.379183
12	4313.447519	93.891017
13	779.947617	89.106183
14	2585.576073	89.809821

[15 rows x 23 columns]

```
[13]: # =====
# Paso 7.1: Calculos derivados de las variables de salida (Ej: Densidad de
# potencia)
# =====
# Añadimos las columnas que queramos obtener como resultado de cálculos con las
# variables de salida.
motors['p12::BSP_wPOT'] = motors['p7::BSP_Pm']/motors['p1::W']
motors['p13::BSP_kt'] = motors['p5::BSP_T']/motors['p9::BSP_Irms']

display(motors.head(15))

# Guardar el DataFrame de los motores generados en formato CSV
model_file = os.path.join(modelo_path, "generated_motors.csv")
motors.to_csv(model_file, index=False)
print("Base de datos de 10,000 motores guardada en:", modelo_path)
```

	x1::OSD	x2::Dint	x3::L	x4::tm	x5::hs2	x6::wt	x7::Nt	\
0	59.109233	31.737597	31.857104	3.038212	8.100607	2.862901	19	
1	59.328662	25.186221	36.345354	3.184483	5.897683	2.917327	10	
2	56.160596	27.553930	15.929237	2.550499	8.694059	4.861692	29	
3	57.901684	31.469801	28.003841	2.484687	7.803684	4.070863	5	
4	57.872131	28.719523	22.667203	3.251350	6.544124	2.336454	20	

5	52.032954	25.642214	19.145558	3.351096	8.292027	4.708284	10
6	59.022678	30.102536	20.725107	3.232948	8.300313	4.880363	26
7	59.084247	23.506281	33.429104	2.176902	12.881647	3.738299	10
8	59.755479	29.172891	20.501322	2.071435	7.684031	2.163283	30
9	58.495452	23.956231	22.701931	3.328490	13.620656	2.710177	29
10	54.892270	27.079011	32.339341	3.050077	8.790003	2.443443	8
11	59.557619	29.147132	17.652638	3.129924	5.193074	2.318498	17
12	55.110892	26.975004	33.937222	2.244937	6.909910	4.422841	11
13	56.524556	32.208991	22.513839	3.210961	8.131219	3.047029	29
14	57.114990	33.602851	32.270730	2.398497	6.025044	3.636245	15

	x8::Nh	m1::Drot	m2::Dsh	...	p4::GFF	p5::BSP_T	p6::BSP_n	\
0	9	30.737597	15.593288	...	121.683401	2.195488	-899.790235	
1	5	24.186221	10.621192	...	79.164804	0.786514	3929.156938	
2	6	26.553930	13.580381	...	118.831479	0.990222	3.527924	
3	4	30.469801	16.509056	...	18.483142	0.303060	9698.199115	
4	8	27.719523	13.011245	...	129.987080	1.267237	1118.107567	
5	9	24.642214	10.613676	...	94.679272	0.730050	6639.036286	
6	7	29.102536	14.035915	...	126.125566	1.472640	-1020.992272	
7	3	22.506281	11.436397	...	17.571305	0.391729	5171.823947	
8	9	28.172891	15.694910	...	133.769191	1.050829	-1929.044073	
9	9	22.956231	9.454615	...	100.507478	1.150322	-1405.642051	
10	4	26.079011	12.241997	...	24.593303	0.446300	6355.251622	
11	7	28.147132	13.559531	...	124.018366	0.843218	3236.366880	
12	9	25.975004	13.777985	...	115.591728	1.467850	2610.183051	
13	3	31.208991	15.584499	...	69.087639	0.942382	599.422861	
14	7	32.602851	18.205043	...	111.126049	1.828527	1134.229564	

	p7::BSP_Pm	p8::BSP_Mu	p9::BSP_Irms	p10::MSP_n	p11::UWP_Mu	\
0	455.875568	80.376615	22.625179	414.861528	88.645633	
1	355.540030	89.221634	12.580649	4947.391460	92.228441	
2	198.335769	77.244850	14.958926	3205.291516	95.466488	
3	304.440999	89.972861	10.057482	10232.612990	87.166049	
4	416.918003	80.546046	20.088639	3684.173703	90.843749	
5	525.634760	90.026268	22.623560	9849.559652	93.973760	
6	258.078796	78.270538	17.490562	1889.461643	94.751823	
7	211.433877	87.473022	7.568995	6103.216045	88.430043	
8	259.761539	75.457806	22.323881	1083.331967	89.947109	
9	246.165757	73.158322	22.359127	1565.227176	91.293506	
10	300.436897	88.765449	10.057775	6908.425001	85.906202	
11	433.204842	85.452662	17.581354	5973.476339	91.379183	
12	498.616377	87.017205	22.637501	4313.447519	93.891017	
13	187.331615	77.982601	7.592398	779.947617	89.106183	
14	426.674349	84.610137	17.626277	2585.576073	89.809821	

	p12::BSP_wPOT	p13::BSP_kt
0	425.118369	0.097037
1	374.394561	0.062518

2	298.703113	0.066196
3	480.385304	0.030133
4	501.393378	0.063082
5	952.479490	0.032269
6	309.472096	0.084196
7	303.526520	0.051754
8	273.241087	0.047072
9	270.531117	0.051448
10	473.056175	0.044374
11	637.057022	0.047961
12	541.639811	0.064842
13	298.936675	0.124122
14	456.007821	0.103739

[15 rows x 25 columns]

Base de datos de 10,000 motores guardada en: C:\Users\s00244\Documents\GitHub\MotorDesignDataDriven\Notebooks_TFM\4.DBG\Modelos_DBG\1000_MOT_Uniforme

```
[14]: # =====
# Paso 8: Filtrar motores válidos según constraints definidos
# =====
def is_valid_motor(row):
    constraints = [
        lambda r: 0.15 <= r['p1::W'] <= 1,      # p1::W entre 0.15 y 1
        lambda r: r['p4::GFF'] >= 1 and r['p4::GFF'] <= 60,
        lambda r: r['p5::BSP_T'] >= 0.5,
        lambda r: r['p6::BSP_n'] >= 3000,
        lambda r: 85 <= r['p8::BSP_Mu'] <= 99,    # p7::BSP_Mu entre 50 y 99
        lambda r: r['p10::MSP_n'] >= 4000,
        lambda r: 80 <= r['p11::UWP_Mu'] <= 99,    # p9::UWP_Mu entre 90 y 99
        # Puedes agregar más restricciones aquí, por ejemplo:
        # lambda r: r['p4::GFF'] >= 1 and r['p4::GFF'] <= 100,
    ]
    return all(condition(row) for condition in constraints)

motors['Valid'] = motors.apply(is_valid_motor, axis=1)
valid_motors = motors[motors['Valid']]
print(f"Número de motores válidos: {len(valid_motors)}")
```

Número de motores válidos: 571

```
[15]: ##### Ordenar los motores válidos por 'p9::UWP_Mu' de menor a mayor
sorted_motors = valid_motors.sort_values(by='p8::BSP_Mu', ascending=False)
print("Motores válidos ordenados por 'p8::BSP_Mu' (de menor a mayor):")
display(sorted_motors.head(10))
```

Motores válidos ordenados por 'p9::UWP_Mu' (de menor a mayor):

x1::OSD	x2::Dint	x3::L	x4::tm	x5::hs2	x6::wt	x7::Nt	\
---------	----------	-------	--------	---------	--------	--------	---

9184	57.041319	29.484630	28.754743	3.257452	6.863795	4.267748	5
4276	57.446000	31.921637	31.476593	3.399687	6.906188	4.365567	5
850	59.007096	31.636367	38.951430	2.376020	6.576349	4.471652	5
3754	59.780590	25.655533	34.595331	2.404886	7.381689	4.139312	5
9077	52.967728	29.487177	31.351064	2.271805	7.256960	4.774430	5
1422	58.132522	32.494782	31.662778	2.604776	7.214700	4.112501	5
2635	52.068865	29.659137	33.385578	2.770355	6.781876	4.271929	5
1426	55.798289	35.123574	30.489771	2.199016	6.523112	4.563930	5
4897	55.906188	27.554639	25.533559	2.946039	7.196884	2.971461	5
9153	59.663450	33.171298	35.794893	2.947976	7.366636	4.723034	5

	x8::Nh	m1::Drot	m2::Dsh	...	p5::BSP_T	p6::BSP_n	p7::BSP_Pm	\
9184	8	28.484630	13.545546	...	0.612439	9557.507427	609.910881	
4276	8	30.921637	15.001795	...	0.742987	7995.338998	612.737091	
850	8	30.636367	16.845365	...	0.901542	6565.322157	608.131774	
3754	7	24.655533	12.515609	...	0.528697	9451.994441	525.863221	
9077	8	28.487177	15.518659	...	0.663647	8468.919235	604.421710	
1422	9	31.494782	17.001007	...	0.857206	7890.659177	684.488263	
2635	8	28.659137	14.644387	...	0.718730	8128.310456	607.365852	
1426	9	34.123574	19.690235	...	0.897241	7248.191995	681.576571	
4897	9	26.554639	12.789808	...	0.543645	12098.613665	678.966370	
9153	7	32.171298	16.797832	...	0.791267	6598.592032	538.945523	

	p8::BSP_Mu	p9::BSP_Irms	p10::MSP_n	p11::UWP_Mu	p12::BSP_wPOT	\
9184	93.350519	20.145856	10518.805629	91.114797	858.285979	
4276	93.063910	20.136600	8838.919783	89.370271	800.205731	
850	93.056981	20.125626	7383.503463	89.622715	631.615362	
3754	93.012863	17.620511	10383.646297	91.753311	598.423956	
9077	92.972180	20.129219	9589.389682	90.609999	902.082436	
1422	92.851507	22.662280	8786.698929	88.365753	867.618938	
2635	92.835788	20.145975	9036.395427	89.830751	889.191876	
1426	92.696555	22.625614	8346.271229	87.016142	935.780800	
4897	92.617758	22.682453	13281.967004	90.109876	1088.201685	
9153	92.607329	17.618577	7513.251613	88.066723	610.757966	

	p13::BSP_kt	Valid
9184	0.030400	True
4276	0.036897	True
850	0.044796	True
3754	0.030005	True
9077	0.032969	True
1422	0.037825	True
2635	0.035676	True
1426	0.039656	True
4897	0.023968	True
9153	0.044911	True

[10 rows x 26 columns]

```
[16]: # =====
# Paso 9: Calcular y representar la frontera de Pareto
# =====
# Objetivos: minimizar p1::W, maximizar p8::BSP_Mu y p9::UWP_Mu
def compute_pareto_front(df, objectives):
    is_dominated = np.zeros(len(df), dtype=bool)
    for i in range(len(df)):
        for j in range(len(df)):
            if i == j:
                continue
            dominates = True
            for obj, sense in objectives.items():
                if sense == 'min':
                    if df.iloc[j][obj] > df.iloc[i][obj]:
                        dominates = False
                        break
                elif sense == 'max':
                    if df.iloc[j][obj] < df.iloc[i][obj]:
                        dominates = False
                        break
            if dominates:
                is_dominated[i] = True
                break
    frontier = df[~is_dominated]
    return frontier

objectives = {'p1::W': 'min', 'p8::BSP_Mu': 'max', 'p12::BSP_wPOT': 'max'}
valid_motors_reset = valid_motors.reset_index(drop=True)
pareto_motors = compute_pareto_front(valid_motors_reset, objectives)
print(f"Número de motores en la frontera de Pareto: {len(pareto_motors)}")

# Representación 2D: eje X = p9, eje Y = p1
plt.figure(figsize=(12, 6))

# Motores no válidos en negro
plt.scatter(
    motors.loc[~motors['Valid'], 'p8::BSP_Mu'],
    motors.loc[~motors['Valid'], 'p1::W'],
    c='black', label='No válidos', alpha=0.6, edgecolors='none'
)

# Motores válidos (no dominados) en azul
plt.scatter(
    valid_motors['p8::BSP_Mu'],
    valid_motors['p1::W'],
    c='blue', label='Válidos', alpha=0.6, edgecolors='none'
)
```

```

# Motores en la frontera de Pareto en rojo
plt.scatter(
    pareto_motors['p8::BSP_Mu'],
    pareto_motors['p1::W'],
    c='red', label='Frontera Pareto', s=60, marker='o', edgecolors='k'
)

plt.xlabel(r'p8::\mu$')
plt.ylabel('p1::W')
plt.title('Frontera de Pareto en 2D (p8 vs p1)')
plt.legend()
plt.grid(True)
plt.tight_layout()

figure_file_2d = os.path.join(figure_path, "Pareto_frontier_2D.png")
plt.savefig(figure_file_2d, dpi=1000)
print("Figura guardada en:", figure_file_2d)
plt.close()


# Representación 3D de la frontera de Pareto
fig = plt.figure()
ax = fig.add_subplot(111, projection='3d')
ax.scatter(valid_motors['p1::W'], valid_motors['p8::BSP_Mu'], valid_motors['p12::BSP_wPOT'],
           c='blue', label='Válidos', alpha=0.5)
ax.scatter(motors[~motors['Valid']]['p1::W'], motors[~motors['Valid']]['p8::BSP_Mu'], motors[~motors['Valid']]['p12::BSP_wPOT'],
           c='red', label='No válidos', alpha=0.5)
ax.scatter(pareto_motors['p1::W'], pareto_motors['p8::BSP_Mu'], pareto_motors['p12::BSP_wPOT'],
           c='green', label='Frontera Pareto', s=100, marker='D')
ax.set_xlabel('p1::W')
ax.set_ylabel('p8::BSP_Mu')
ax.set_zlabel('p12::BSP_wPOT')
ax.legend()
plt.title('Frontera de Pareto de diseños de motores')
plt.show()

```

Número de motores en la frontera de Pareto: 13

Figura guardada en: C:\Users\s00244\Documents\GitHub\MotorDesignDataDriven\Notebooks_TFM\4.DBG\Figuras_DBG\1000_MOT_Uniforme\Pareto_frontier_2D.png

Frontera de Pareto de diseños de motores



```
[17]: # Si existen motores válidos, procedemos a la selección:
if len(valid_motors) > 0:
    # 1. Motor más liviano: mínimo de p1::W
    motor_liviano = valid_motors.loc[valid_motors['p1::W'].idxmin()]

    # 2. Motor más eficiente: máximo de p8::BSP_Mu (asumiendo que mayor p9::
    # ↳ UWP_Mu indica mayor eficiencia)
    motor_eficiente = valid_motors.loc[valid_motors['p8::BSP_Mu'].idxmax()]

    # 3. Motor más eficiente y liviano:
    # Se normalizan p1::W y p9::UWP_Mu en el subconjunto de motores válidos.
    vm = valid_motors.copy()
    # Normalizar p1::W (donde un menor valor es mejor, así que se invertirá)
    vm['p1::W_norm'] = (vm['p1::W'] - vm['p1::W'].min()) / (vm['p1::W'].max() -
    # ↳ vm['p1::W'].min())
    # Normalizar p8::BSP_Mu (mayor es mejor)
    vm['p8::BSP_Mu_norm'] = (vm['p8::BSP_Mu'] - vm['p8::BSP_Mu'].min()) /
    # ↳ (vm['p8::BSP_Mu'].max() - vm['p8::BSP_Mu'].min())
    # Normalizar p12::BSP_wPOT (mayor es mejor)
    vm['p12::BSP_wPOT_norm'] = (vm['p12::BSP_wPOT'] - vm['p12::BSP_wPOT'].
    # ↳ min()) / (vm['p12::BSP_wPOT'].max() - vm['p12::BSP_wPOT'].min())
```

```

# Definir un score compuesto: se busca minimizar p1::W (por ello, usamos 1_
↪ normalizado) y maximizar p8::BSP_Mu
vm['composite_score'] = (1 - vm['p1::W_norm']) + vm['p8::BSP_Mu_norm']
motor_eficiente_liviano = vm.loc[vm['composite_score'].idxmax()]

# Mostrar las soluciones:
print("\nMotor más liviano:")
print(motor_liviano)

print("\nMotor más eficiente:")
print(motor_eficiente)

print("\nMotor más eficiente y liviano (score compuesto):")
print(motor_eficiente_liviano)

# Opcional: Guardar cada solución en un CSV separado
#motor_liviano.to_frame().T.to_csv("motor_mas_liviano.csv", index=False)
# motor_eficiente.to_frame().T.to_csv("motor_mas_eficiente.csv",_
↪ index=False)
# motor_eficiente_liviano.to_frame().T.to_csv("motor_eficiente_y_liviano.
↪ csv", index=False)
# print("\nSoluciones guardadas en CSV.")
else:
    print("No se encontraron motores válidos. Verifique las constraints y el_
↪ escalado de los datos.")

```

Motor más liviano:

x1::OSD	57.89255
x2::Dint	29.469571
x3::L	13.348
x4::tm	3.122518
x5::hs2	9.766914
x6::wt	2.942228
x7::Nt	15
x8::Nh	6
m1::Drot	28.469571
m2::Dsh	13.804658
m3::he	4.444576
m4::Rmag	13.454156
m5::Rs	24.501699
m6::GFF	51.362921
p1::W	0.469023
p4::GFF	58.436128
p5::BSP_T	0.578618
p6::BSP_n	6631.444627

p7::BSP_Pm 390.805603
 p8::BSP_Mu 87.629198
 p9::BSP_Irms 15.10486
 p10::MSP_n 8105.883682
 p11::UWP_Mu 90.511919
 p12::BSP_wPOT 833.233806
 p13::BSP_kt 0.038307
 Valid True
 Name: 7474, dtype: object

Motor más eficiente:

x1::OSD 57.041319
 x2::Dint 29.48463
 x3::L 28.754743
 x4::tm 3.257452
 x5::hs2 6.863795
 x6::wt 4.267748
 x7::Nt 5
 x8::Nh 8
 m1::Drot 28.48463
 m2::Dsh 13.545546
 m3::he 6.91455
 m4::Rmag 13.427952
 m5::Rs 21.60611
 m6::GFF 45.367167
 p1::W 0.710615
 p4::GFF 53.606973
 p5::BSP_T 0.612439
 p6::BSP_n 9557.507427
 p7::BSP_Pm 609.910881
 p8::BSP_Mu 93.350519
 p9::BSP_Irms 20.145856
 p10::MSP_n 10518.805629
 p11::UWP_Mu 91.114797
 p12::BSP_wPOT 858.285979
 p13::BSP_kt 0.0304
 Valid True
 Name: 9184, dtype: object

Motor más eficiente y liviano (score compuesto):

x1::OSD 57.165948
 x2::Dint 34.97629
 x3::L 19.604869
 x4::tm 2.938846
 x5::hs2 6.859336
 x6::wt 4.624641
 x7::Nt 6
 x8::Nh 8


```

m1::Drot          33.97629
m2::Dsh           18.105372
m3::he            4.235494
m4::Rmag          16.253433
m5::Rs            24.347481
m6::GFF           45.181414
p1::W             0.549823
p4::GFF           55.091781
p5::BSP_T         0.615264
p6::BSP_n         9356.209039
p7::BSP_Pm        603.97592
p8::BSP_Mu        92.536375
p9::BSP_Irms      20.136878
p10::MSP_n        10639.211197
p11::UWP_Mu       89.725893
p12::BSP_wPOT     1098.491564
p13::BSP_kt       0.030554
Valid             True
p1::W_norm        0.160186
p8::BSP_Mu_norm   0.902394
p12::BSP_wPOT_norm 0.790996
composite_score   1.742208
Name: 8649, dtype: object

```

```

[18]: # =====
# Paso 10: Seleccionar el motor válido óptimo
# =====
# Se normalizan los objetivos y se define un score compuesto
valid_motors_comp = valid_motors.copy()
for col, sense in [('p1::W', 'min'), ('p8::BSP_Mu', 'max'), ('p12::BSP_wPOT', 'max')]:
    col_min = valid_motors_comp[col].min()
    col_max = valid_motors_comp[col].max()
    if sense == 'min':
        valid_motors_comp[col + '_norm'] = 1 - (valid_motors_comp[col] -
        col_min) / (col_max - col_min)
    else:
        valid_motors_comp[col + '_norm'] = (valid_motors_comp[col] - col_min) /
        (col_max - col_min)

valid_motors_comp['composite_score'] = (valid_motors_comp['p1::W_norm'] +
                                         valid_motors_comp['p8::BSP_Mu_norm'] +
                                         valid_motors_comp['p12::
        BSP_wPOT_norm'])
optimal_motor = valid_motors_comp.loc[valid_motors_comp['composite_score'].
        idxmax()]
print("Motor válido óptimo (según score compuesto):")

```

```
print(optimal_motor)

model_file = os.path.join(model_path, "optimal_motor.csv")
optimal_motor.to_frame().T.to_csv(model_file, index=False)
print("El motor óptimo se ha guardado en:", model_path)
```

Motor válido óptimo (según score compuesto):

x1::OSD	54.956163
x2::Dint	29.744712
x3::L	18.937528
x4::tm	2.533385
x5::hs2	8.747622
x6::wt	2.504537
x7::Nt	7
x8::Nh	9
m1::Drot	28.744712
m2::Dsh	15.179452
m3::he	3.858104
m4::Rmag	13.73901
m5::Rs	23.619978
m6::GFF	38.856007
p1::W	0.495859
p4::GFF	45.529899
p5::BSP_T	0.540438
p6::BSP_n	11624.167634
p7::BSP_Pm	658.124721
p8::BSP_Mu	90.590176
p9::BSP_Irms	22.682105
p10::MSP_n	12790.473124
p11::UWP_Mu	87.780375
p12::BSP_wPOT	1327.242788
p13::BSP_kt	0.023827
Valid	True
p1::W_norm	0.946798
p8::BSP_Mu_norm	0.669069
p12::BSP_wPOT_norm	1.0
composite_score	2.615867

Name: 447, dtype: object

El motor óptimo se ha guardado en: C:\Users\s00244\Documents\GitHub\MotorDesignD
ataDriven\Notebooks_TFM\4.DBG\Modelos_DBG

[]: